HUST

ĐẠI HỌC BÁCH KHOA HÀ NỘI

HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

ONE LOVE. ONE FUTURE.

HỆ GỢI Ý (IT4613)

HỆ GỢI Ý

GỢI Ý DỰA TRÊN LỌC CỘNG TÁC CƠ BẢN

Nội dung môn học

- Giới thiệu về Hệ gợi ý
- **Gợi ý dựa trên lọc cộng tác: Cơ bản** và Các kỹ thuật nâng cao
- Gợi ý dựa trên nội dung
- Gợi ý dựa trên tri thức
- Gợi ý dựa trên phiên
- Kết hợp các kỹ thuật gợi ý
- Đánh giá hiệu quả đối với hệ gợi ý
- Ứng dụng kỹ thuật học sâu trong hệ gợi ý: Bài toán gợi ý tin tức
- Ứng dụng kỹ thuật học sâu trong hệ gợi ý: Học tương phản

Lọc cộng tác (Collaborative Filtering)



Nội dung

- Lọc cộng tác (CF)
  - Ý tưởng của lọc cộng tác
  - Lọc cộng tác dựa trên láng giềng gần của user
  - Lọc cộng tác dựa trên láng giềng gần của item
  - Vấn đề với dữ liệu thưa
  - Học biểu diễn ẩn của user và item dựa trên phân tích ma trận
  - Tài liệu tham khảo

1. Lọc cộng tác: Ý tưởng

- Là các tiếp cận nổi bật để đưa ra gợi ý:
  - Được sử dụng bởi nhiều các hệ thống thương mại điện tử
  - Có nhiều thuật toán và các biến thể
  - Áp dụng trong nhiều domains (news, book, movies, DVDs, ..)
- Tiếp cận:
  - Dựa trên "wisdom of the crowd" để gợi ý items



- Giả thiết và ý tưởng:
  - Users đưa ra ratings cho các items (implicit hoặc explicit feedback)
  - Users có sở thích tương tự nhau trong quá khứ, cũng sẽ có sở thích tương tự trong tương lai

Lọc cộng tác: Ý tưởng

- Input
  - Only a matrix of given user–item ratings
- Output types
  - A (numerical) prediction indicating to what degree the current user will like or dislike a certain item
  - A top-N list of recommended items

Tiếp cận dựa trên bộ nhớ (memory)

- Lọc cộng tác dựa trên láng giềng là tiếp cận dựa trên bộ nhớ
  - Ma trận ratings được sử dụng trực tiếp để tìm láng giềng của users hoặc items và đưa ra gợi ý
    - Ví dụ: Với một user, cách tiếp cận sẽ tìm ra những láng giềng là users tương tự. Danh sách gợi ý cho user sẽ xây dựng từ các items mà users tương tự đã thích.
  - Chỉ lưu trữ dữ liệu trong bước training
  - Khó làm việc với dữ liệu lớn

Tiếp cận dựa trên mô hình (model)

- Lọc cộng tác dựa trên mô hình
  - Phải xây dựng và huấn luyện mô hình trước
  - Ở thời điểm gợi ý, mô hình sau khi huấn luyện được sử dụng để đưa ra dự đoán, gợi ý
  - Mô hình phải được cập nhật sau một giai đoạn thời gian
  - Có đa dạng các kiểu mô hình đã được xây dựng
  - Xây dựng mô hình và huấn luyện có thể yêu cầu khối lượng tính toán lớn

2. Lọc cộng tác dựa trên láng giềng gần của user

- Bài toán:
  - Cho một "active user" (Alice) và một item i mà Alice chưa biết
    - Tìm một tập các users mà đã thích các items giống như Alice trong quá khứ, và đã đánh giá sản phẩm item i
    - Sử dụng đánh giá trung bình của tập users để đánh giá mức độ Alice thích item i
    - Thực hiện việc này cho tất cả các items mà Alice chưa thấy để gợi ý các items có khả năng ưa thích nhất
- Giả thiết và ý tưởng:
  - Users có sở thích tương tự nhau trong quá khứ, cũng sẽ có sở thích tương tự trong tương lai
  - Sở thích của users ổn định, không thay đổi theo thời gian

Lọc cộng tác dựa trên láng giềng gần của user

- Ví dụ
  - Cho ma trận ratings của các users hiện tại

	Item1	Item2	Item3	Item4	Item5
Alice	5	3	4	4	?
User1	3	1	2	3	3
User2	4	3	4	3	5
User3	3	3	1	5	4
User4	1	5	5	2	1

  - Xác định Alice có thích hay không thích *Item5?*

Lọc cộng tác dựa trên láng giềng gần của user

- Một số câu hỏi đầu tiên cho cách tiếp cận này:
  - Độ đo tương đồng?
  - Số lượng láng giềng?
  - Cách sinh ra rating từ ratings của tập các láng giềng?



	Item1	Item2	Item3	Item4	Item5
Alice	5	3	4	4	?
User1	3	1	2	3	3
User2	4	3	4	3	5
User3	3	3	1	5	4
User4	1	5	5	2	1

Độ đo tương đồng (1)

- Độ đo tương đồng phổ biến cho user-based CF: **Pearson correlation**

  a, b : users

  $r_{a,p}$: rating of user a for item p

  P : set of items, rated both by a and b

  - Possible similarity values between -1 and 1

$$sim(a,b) = \frac{\sum_{p \in P}(r_{a,p} - \bar{r}_a)(r_{b,p} - \bar{r}_b)}{\sqrt{\sum_{p \in P}(r_{a,p} - \bar{r}_a)^2}\sqrt{\sum_{p \in P}(r_{b,p} - \bar{r}_b)^2}}$$

Độ đo tương đồng (2)

- Độ đo tương đồng phổ biến cho user-based CF: **Pearson correlation**

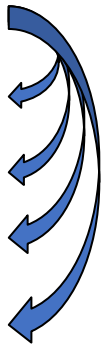
  a, b : users

  $r_{a,p}$: rating of user a for item p

  P : set of items, rated both by a and b

  - Possible similarity values between -1 and 1

	Item1	Item2	Item3	Item4	Item5
Alice	5	3	4	4	?
User1	3	1	2	3	3
User2	4	3	4	3	5
User3	3	3	1	5	4
User4	1	5	5	2	1



sim = 0,85

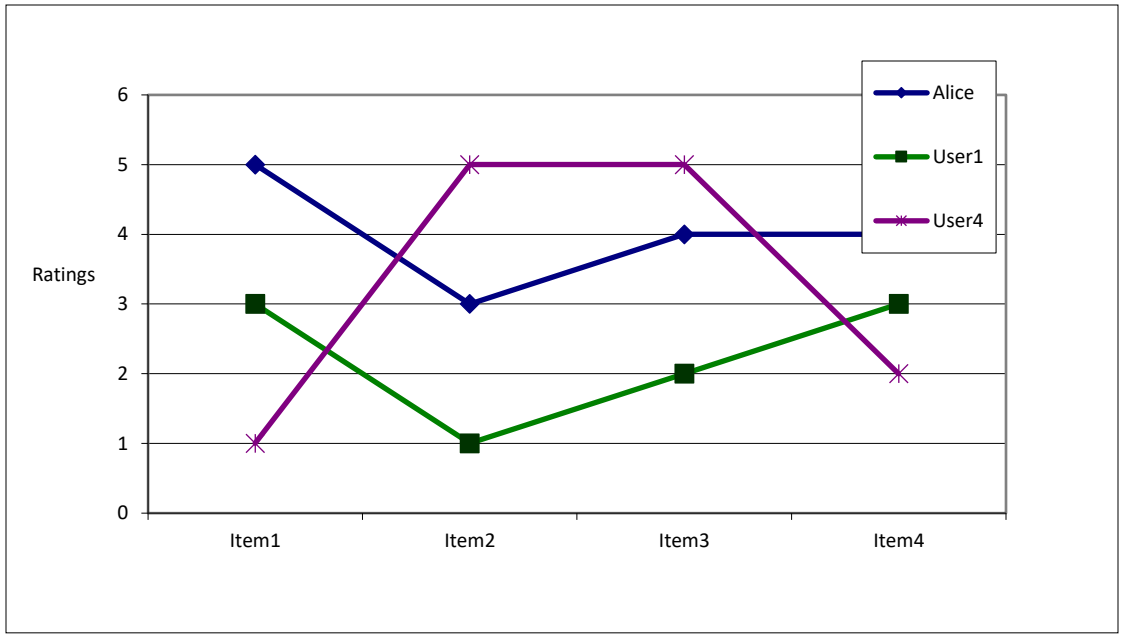
sim = 0,00

sim = 0,70

sim = -0,79

Pearson correlation

- Minh họa



- Làm việc tốt trong nhiều bài toán khi so với:
  - Độ đo tương đồng cosine

Dự đoán

- Hàm dự đoán phổ biến:

$$pred(a,p) = \overline{r_a} + \frac{\sum_{b \in N} sim(a,b) * (r_{b,p} - \overline{r_b})}{\sum_{b \in N} sim(a,b)}$$



- Tính toán điểm mỗi láng giềng trên item p so với điểm trung bình của họ
- Kết hợp điểm trung bình của các láng giềng với trọng số tương đồng của user a
- Cộng với mức độ bias của user a

Cải thiện hàm dự đoán

- Không phải tất cả các ratings của láng giềng đều có giá trị tương đương
  - Đồng thuận trên các items được thích phổ biến sẽ không mang lại nhiều thông tin như đồng thuận trên các items có nhiều đánh giá trái ngược
  - **Possible solution**: Đặt trọng số cao hơn trên các items mà có đánh giá là higher variance

Cải thiện hàm dự đoán

- Số lượng của các items mà 2 users cùng tương tác
  - Trọng số sẽ giảm khi 2 users có ít items tương tác chung
- Tăng trọng số láng giếng
  - Trực quan: Đặt trọng số gần 1 khi cặp users là rất tương đồng.
- Lựa chọn láng giềng
  - Dựa trên ngưỡng tương đồng hoặc số cố định các láng giềng

3. Lọc cộng tác dựa trên item

- Ý tưởng:
  - Sử dụng độ tương đồng giữa các items để đưa ra gợi ý
- Ví dụ:
  - Tìm kiếm items mà tương tự với Item5
  - Sử dụng ratings của Alice cho những items này để dự đoán rating cho Item5

	Item1	Item2	Item3	Item4	Item5
Alice	5	3	4	4	?
User1	3	1	2	3	3
User2	4	3	4	3	5
User3	3	3	1	5	4
User4	1	5	5	2	1

Độ đo tương đồng cosin

- Đưa ra kết quả tốt trong lọc dựa trên item-to-item
- Các ratings có thể xem như vector trong không gian n chiều
- Độ tương đồng được tính dựa trên góc giữa các vectors này

$$sim(\vec{a}, \vec{b}) = \frac{\vec{a} \cdot \vec{b}}{|\vec{a}| * |\vec{b}|}$$



- Điều chỉnh cho lọc dựa trên item
  - Tính điểm trung bình của các users đã rate cho mỗi item
  - U: là tập users đã đánh giá cho cả a và b

$$sim(\vec{a}, \vec{b}) = \frac{\sum_{u \in U}(r_{u,a} - \overline{r_u})(r_{u,b} - \overline{r_u})}{\sqrt{\sum_{u \in U}(r_{u,a} - \overline{r_u})^2} \sqrt{\sum_{u \in U}(r_{u,b} - \overline{r_u})^2}}$$



Đưa ra gợi ý

- Hàm gợi ý:

$$pred(u,p) = \frac{\sum_{i \in ratedItem(u)} sim(i,p) * r_{u,i}}{\sum_{i \in ratedItem(u)} sim(i,p)}$$



- Số lượng láng giềng phải lựa chọn cụ thể
- Không phải tất cả láng giềng đều nên được lựa chọn để dự đoán
- Phân tích thực nghiệm trên MovieLens gợi ý rằng “số lượng láng giềng nên đặt 20 tới 50 " (Herlocker et al. 2002)

Tiền xử lý cho lọc dựa trên items

- Lọc dựa trên items khó mở rộng hệ thống lớn
- Tiền xử lý trước như hệ thống Amazon.com (năm 2003)
  - Tính toán tất cả các cặp tương đồng của items trước
  - Láng giềng được sự dụng lúc gợi ý thường nhỏ bởi vì chỉ xét tới một số lượng items được gợi ý
  - Gợi ý tương đồng dựa trên items thường không đa dạng

Tiền xử lý cho lọc dựa trên items

- Yêu cầu bộ nhớ
  - Về lý thuyết, có thể lên tới N^2 cặp tương đồng được lưu trữ (N = số lượng items)
  - Thực tế, số lượng lưu trữ nhỏ hơn đang kể (items không có rating bởi cùng user)
  - Có thể giảm kích thước bộ nhớ
    - Sử dụng ngưỡng tối thiểu co-ratings
    - Giới hạn số lượng láng giềng

4. Vấn đề với dữ liệu thưa

- Vấn đề Cold start
  - Khi có users hoặc items mới, làm sao thực hiện được quá trình gợi ý?
- Một số cách đơn giản:
  - Yêu cầu/ Ép buộc users mới đánh giá cho 1 tập items
  - Sử dụng phương pháp khác (ví dụ. content-based, demographic or simply non-personalized) trong giai đoạn ban đầu khi user mới sử dụng hệ thống
  - Đưa danh sách mặc định: assign default values to items that only one of the two users to be compared has rated (Breese et al. 1998)

Vấn đề với dữ liệu thưa

- Một số cách khác
  - Sử dụng thuật toán tốt hơn, đặc thù cho vấn đề này
  - Ví dụ:
    - Trong tiếp cận dựa trên láng giếng gần, tập các láng giềng gần có thể quá nhỏ để đưa ra gợi ý tốt
    - Sử dụng giả thiết tính bắc cầu của hàng xóm

Ví dụ: Thuật toán cho dữ liệu thưa

- Recursive CF (Zhang and Pu 2007)
  - Giả sử có một láng giềng rất gần n của u, trong khi u vẫn chưa đánh giá trên item i
  - Ý tưởng:
    - Áp dụng lọc cộng tác lặp đi lặp lại và dự đoán rating cho item i bởi các hàng xóm
    - Sử dụng rating dự đoán thay vì rating trực tiếp

	Item1	Item2	Item3	Item4	Item5
Alice	5	3	4	4	?
User1	3	1	2	3	?
User2	4	3	4	3	5
User3	3	3	1	5	4
User4	1	5	5	2	1

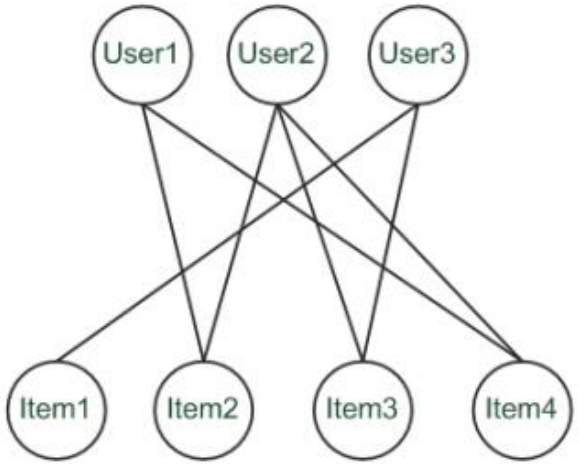


sim = 0.85

Dự đoán Rating cho User1

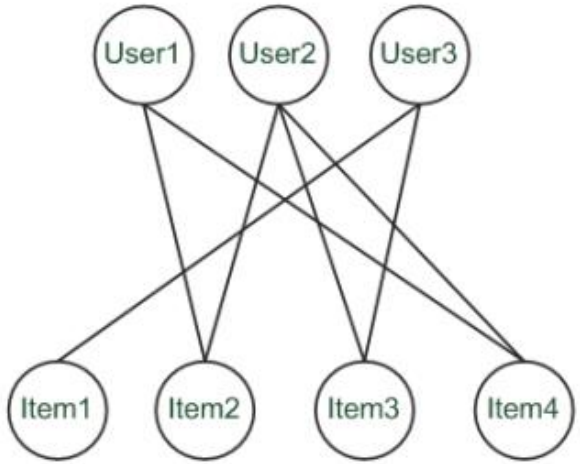
Ví dụ: Phương pháp dựa trên đồ thị

- "Spreading activation" (Huang et al. 2004)
  - Khai thác giả thiết bắc cầu sở thích của khách hàng để bổ sung thêm thông tin
  - Giả sử chúng ta đang phải gợi ý cho User1
  - Khi sử dụng lọc cộng tác thông thường, User2 được xem là láng giềng của User1 bởi vì họ cùng mua Item2 và Item4
  - Vì thế, Item3 sẽ được gợi ý cho User1



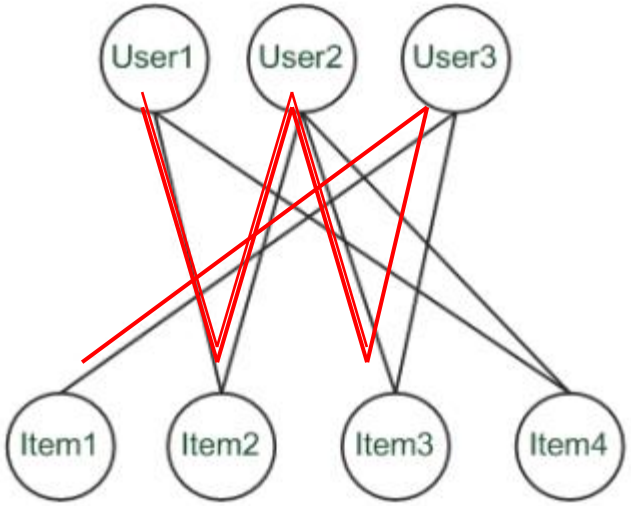
Ví dụ: Phương pháp dựa trên đồ thị

- "Spreading activation" (Huang et al. 2004)
  - Với tiếp cận láng giếng gần, đường đi với độ dài 3 sẽ được sử dụng
  - Ví dụ, *Item3 phù hợp cho User1 bởi vì đường đi với đồ dài 3* (*User1–Item2–User2–Item3*) giữa chúng
  - Idea: Xem xét độ dài lớn hơn (mặc dù không có tương tác trực tiếp) để tính toán cho gợi ý
  - Ví du: Sử dụng đường đi với độ dài 5



Ví dụ: Phương pháp dựa trên đồ thị

- "Spreading activation" (Huang et al. 2004)
  - Idea: Sử dụng đường đi với độ dài > 3 để gợi ý
  - Độ dài 3: Gợi ý Item3 cho User1
  - Độ dài 5: Item1 cũng được gợi ý

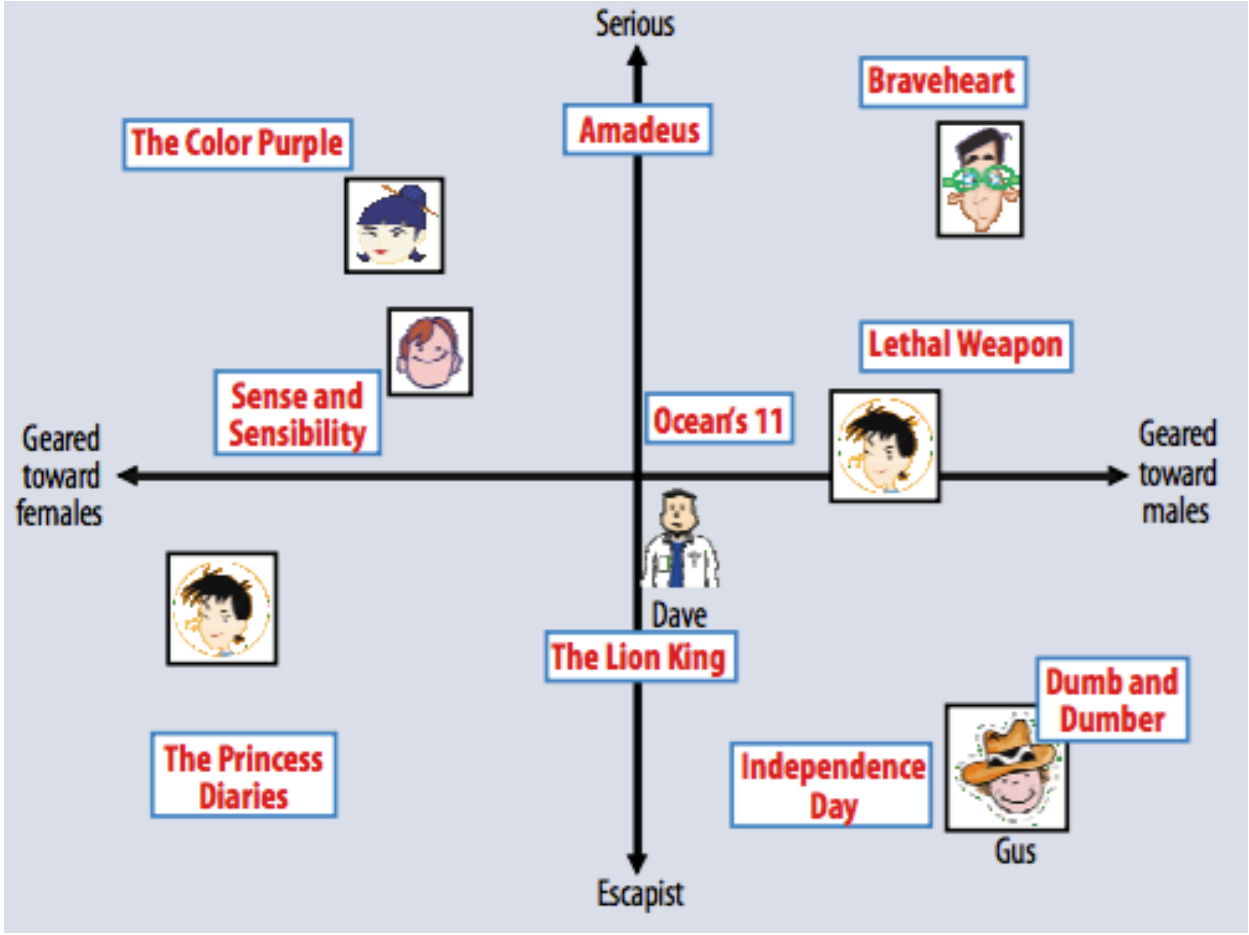


5. Phân tích ma trận (matrix factorization)

- Là tiếp cận dựa trên mô hình
- Được xem như mô hình doubly linear regression
- Giả thiết users và items được biểu diễn trên cùng không gian ẩn mà thể hiện đặc trưng của chúng
- **Gợi ý: Dựa học biểu diễn ẩn của user và item**

Lọc cộng tác dựa trên phân tích ma trận

- Biểu diễn user và item trên cùng không gian



Figures from Koren et al. (2009)

Lọc cộng tác dựa trên phân tích ma trận

- Biểu diễn của user u:

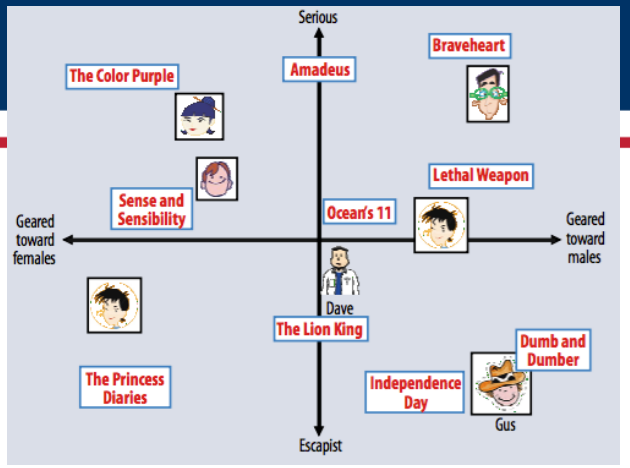
$$(W_{u*})^T \in \mathbb{R}^r$$

- Biểu diễn của item i:

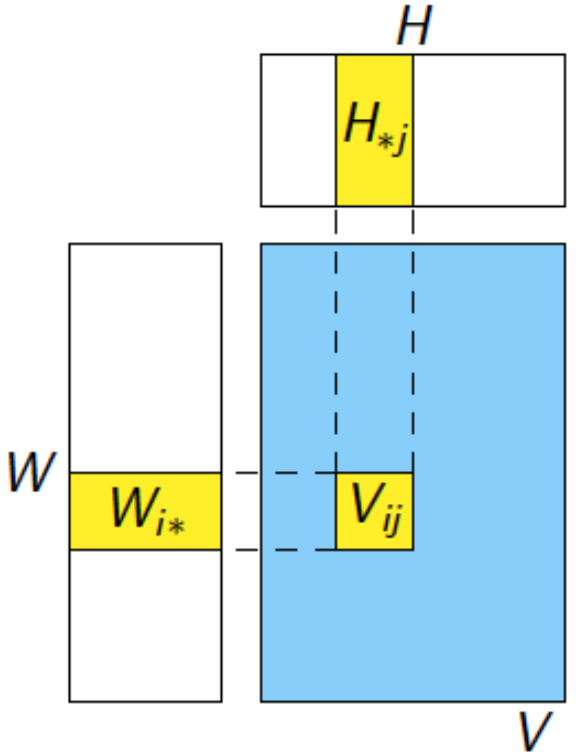
$$H_{*i} \in \mathbb{R}^r$$

- Rating của user u cho item i:

$$V_{ui} = W_{u*} H_{*i}$$
$$= [WH]_{ui}$$



Figures from Koren et al. (2009)



Figures from Gemulla et al. (2011)

Lọc cộng tác dựa trên phân tích ma trận

- User vectors:

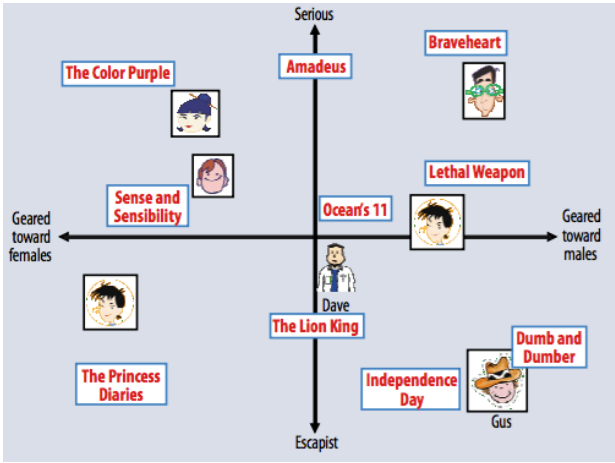
$$\mathbf{w}_u \in \mathbb{R}^r$$

- Item vectors:

$$\mathbf{h}_i \in \mathbb{R}^r$$

- Dự đoán Rating:

$$v_{ui} = \mathbf{w}_u^T \mathbf{h}_i$$



Figures from Koren et al. (2009)

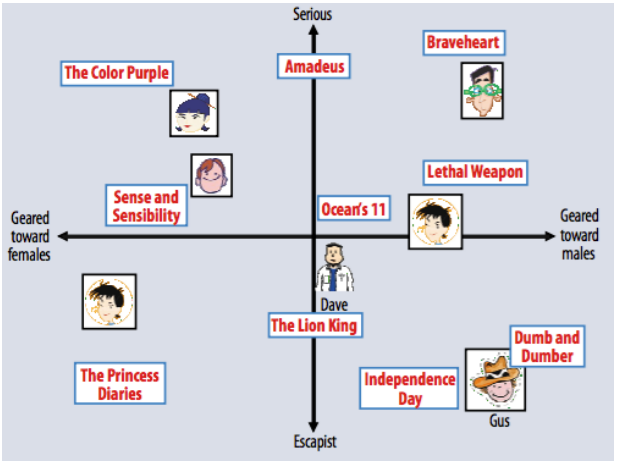
Lọc cộng tác dựa trên phân tích ma trận

- Dữ liệu huấn luyện: Z là tập các cặp user-item có tương tác:

$$\mathcal{Z} = \{(u, i) : v_{ui} \neq 0\}$$

- Hàm mục tiêu:

$$\underset{\mathbf{w},\mathbf{h}}{\operatorname{argmin}} \sum_{(u,i)\in\mathcal{Z}} (v_{ui} - \mathbf{w}_u^T \mathbf{h}_i)^2$$

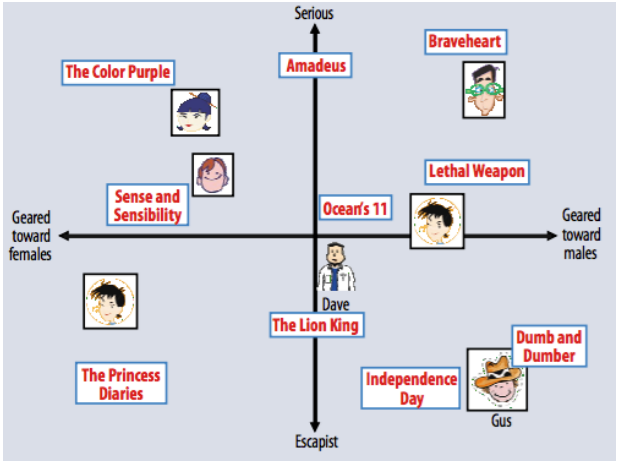


Figures from Koren et al. (2009)

Lọc cộng tác dựa trên phân tích ma trận

- Hàm mục tiêu với đại lượng hiệu chỉnh :

$$\underset{\mathbf{w},\mathbf{h}}{\operatorname{argmin}} \sum_{(u,i)\in\mathcal{Z}} (v_{ui} - \mathbf{w}_u^T \mathbf{h}_i)^2 + \lambda(\sum_i ||\mathbf{w}_i||^2 + \sum_u ||\mathbf{h}_u||^2)$$

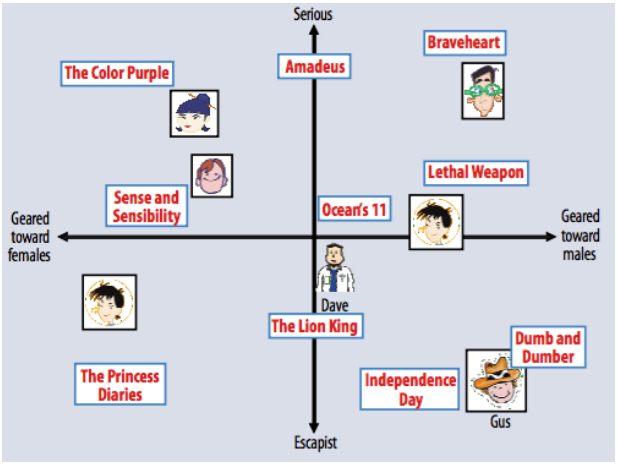


Figures from Koren et al. (2009)

Lọc cộng tác dựa trên phân tích ma trận

- Hàm mục tiêu:

$$\underset{\mathbf{w},\mathbf{h}}{\operatorname{argmin}} \sum_{(u,i)\in\mathcal{Z}} (v_{ui} - \mathbf{w}_u^T \mathbf{h}_i)^2 + \lambda(\sum_i ||\mathbf{w}_i||^2 + \sum_u ||\mathbf{h}_u||^2)$$



Figures from Koren et al. (2009)

- Sử dụng SGD (stochastic gradient descent) để học:

$$e_{ui} \leftarrow v_{ui} - \mathbf{w}_u^T \mathbf{h}_i$$
$$\mathbf{w}_u \leftarrow \mathbf{w}_u + \gamma(e_{ui}\mathbf{h}_i - \lambda \mathbf{w}_u)$$
$$\mathbf{h}_i \leftarrow \mathbf{h}_i + \gamma(e_{ui}\mathbf{w}_u - \lambda \mathbf{h}_i)$$

Lọc cộng tác dựa trên phân tích ma trận

- Thuật toán

require that the loss can be written as

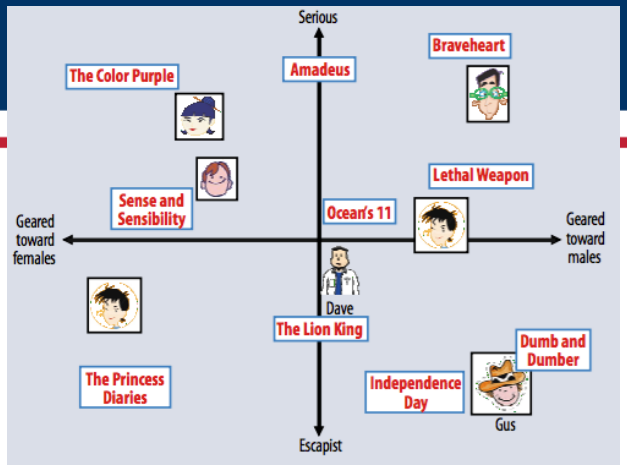
$$L = \sum_{(i,j) \in Z} l(\boldsymbol{V}_{ij}, \boldsymbol{W}_{i*}, \boldsymbol{H}_{*j})$$

Algorithm 1 SGD for Matrix Factorization

Require: A training set Z, initial values $\boldsymbol{W}_0$ and $\boldsymbol{H}_0$
  while not converged **do** {step}
    Select a training point $(i, j) \in Z$ uniformly at random.
    $\boldsymbol{W}'_{i*} \leftarrow \boldsymbol{W}_{i*} - \epsilon_n N \frac{\partial}{\partial \boldsymbol{W}_{i*}} l(\boldsymbol{V}_{ij}, \boldsymbol{W}_{i*}, \boldsymbol{H}_{*j})$
    $\boldsymbol{H}_{*j} \leftarrow \boldsymbol{H}_{*j} - \epsilon_n N \frac{\partial}{\partial \boldsymbol{H}_{*j}} l(\boldsymbol{V}_{ij}, \boldsymbol{W}_{i*}, \boldsymbol{H}_{*j})$
    $\boldsymbol{W}_{i*} \leftarrow \boldsymbol{W}'_{i*}$
  end while

step size

Figure from Gemulla et al. (2011)



Figures from Koren et al. (2009)

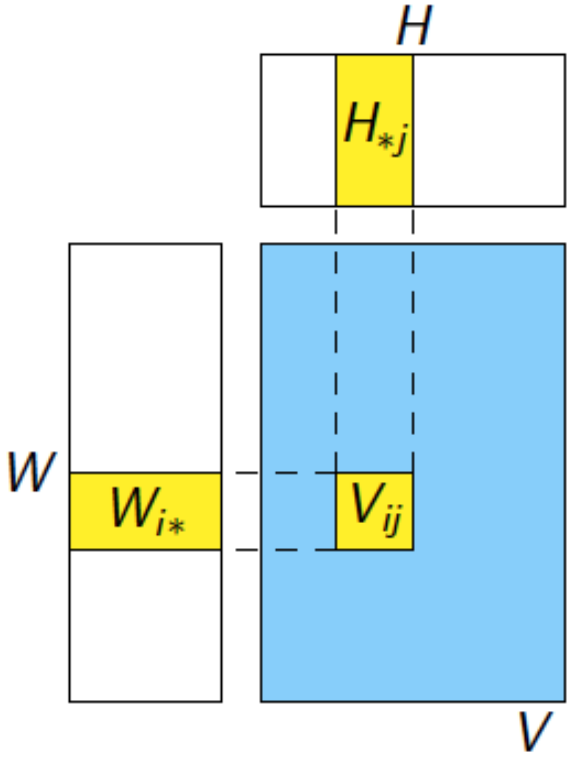


Figure from Gemulla et al. (2011)

Lọc cộng tác dựa trên phân tích ma trận

Ví dụ

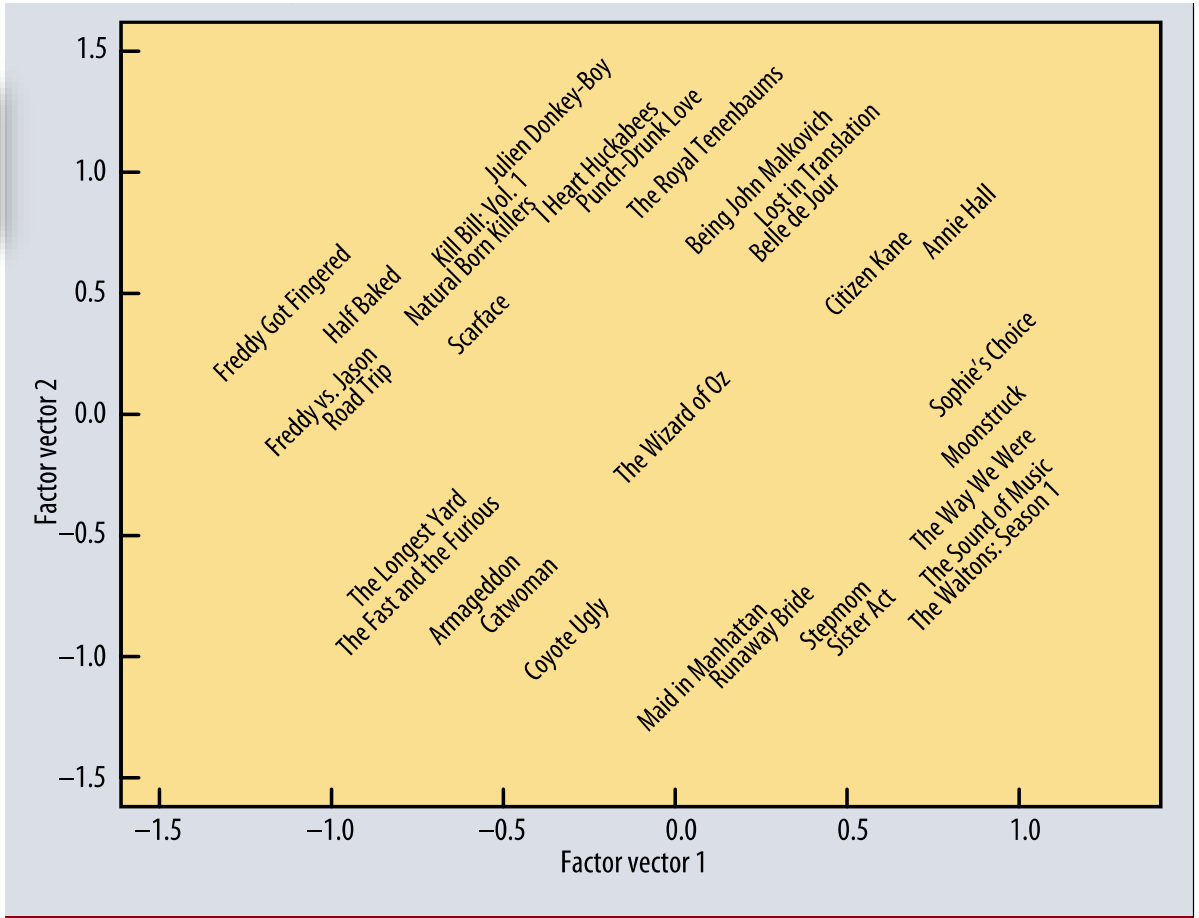


Figure 3. The first two vectors from a matrix decomposition of the Netflix Prize data. Selected movies are placed at the appropriate spot based on their factor vectors in two dimensions. The plot reveals distinct genres, including clusters of movies with strong female leads, fraternity humor, and quirky independent films.

Figure from Koren et al. (2009)

Tài liệu tham khảo

- Slide
  - http://www.recommenderbook.net/teaching-material/slides

- Book

- Dietmar Jannach, Markus Zanker, Alexander Felfernig, Gerhard Friedrich (2010). *Recommender Systems: An Introduction*. Cambridge University Press.
- Francesco Ricci, Lior Rokach, Bracha Shapira, Paul B. Kantor (2015). *Recommender Systems Handbook* (2nd edition). Springer.
- Charu C. Aggarwal (2016). *Recommender Systems: The Textbook*. Springer

Tài liệu tham khảo

- [Adomavicius and Tuzhilin 2005] Toward the next generation of recommender systems: A survey of the state-of-the-art and possible extensions, IEEE Transactions on Knowledge and Data Engineering 17 (2005), no. 6, 734–749
- [Breese et al. 1998] Empirical analysis of predictive algorithms for collaborative filtering, Proceedings of the 14th Conference on Uncertainty in Artificial Intelligence (Madison, WI) (Gregory F. Cooper and Seraf´in Moral, eds.), Morgan Kaufmann, 1998, pp. 43–52
- [Gedikli et al. 2011] RF-Rec: Fast and accurate computation of recommendations based on rating frequencies, Proceedings of the 13th IEEE Conference on Commerce and Enterprise Computing - CEC 2011, Luxembourg, 2011, forthcoming
- [Goldberg et al. 2001] Eigentaste: A constant time collaborative filtering algorithm, Information Retrieval 4 (2001), no. 2, 133–151
- [Golub and Kahan 1965] Calculating the singular values and pseudo-inverse of a matrix, Journal of the Society for Industrial and Applied Mathematics, Series B: Numerical Analysis 2 (1965), no. 2, 205–224
- [Herlocker et al. 2002] An empirical analysis of design choices in neighborhood-based collaborative filtering algorithms, Information Retrieval 5 (2002), no. 4, 287–310
- [Herlocker et al. 2004] Evaluating collaborative filtering recommender systems, ACM Transactions on Information Systems (TOIS) 22 (2004), no. 1, 5–53

Tài liệu tham khảo

- [Hofmann 2004] Latent semantic models for collaborative filtering, ACM Transactions on Information Systems 22 (2004), no. 1, 89–115
- [Huang et al. 2004] Applying associative retrieval techniques to alleviate the sparsity problem in collaborative filtering, ACM Transactions on Information Systems 22 (2004), no. 1, 116–142
- [Koren et al. 2009] *Matrix factorization techniques for recommender systems*, Computer 42 (2009), no. 8, 30–37
- [Lemire and Maclachlan 2005] Slope one predictors for online rating-based collaborative filtering, Proceedings of the 5th SIAM International Conference on Data Mining (SDM '05) (Newport Beach, CA), 2005, pp. 471–480
- [Sarwar et al. 2000a] Application of dimensionality reduction in recommender systems – a case study, Proceedings of the ACM WebKDD Workshop (Boston), 2000
- [Zhang and Pu 2007] A recursive prediction algorithm for collaborative filtering recommender systems, Proceedings of the 2007 ACM Conference on Recommender Systems (RecSys '07) (Minneapolis, MN), ACM, 2007, pp. 57–64

HUST

hust.edu.vn fb.com/dhbkhn

THANK YOU !