# HUST

ĐẠI HỌC BÁCH KHOA HÀ NỘI

HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

ONE LOVE. ONE FUTURE.

# HỆ GỢI Ý (IT4613)

# HỆ GỢI Ý

## LỌC CỘNG TÁC NÂNG CAO

ONE LOVE. ONE FUTURE.

# Nội dung môn học

- Giới thiệu về Hệ gợi ý
- **Gợi ý dựa trên lọc cộng tác:** Cơ bản và **Các kỹ thuật nâng cao**
- Gợi ý dựa trên nội dung
- Gợi ý dựa trên tri thức
- Gợi ý dựa trên phiên
- Kết hợp các kỹ thuật gợi ý
- Đánh giá hiệu quả đối với hệ gợi ý
- Ứng dụng kỹ thuật học sâu trong hệ gợi ý: Bài toán gợi ý tin tức
- Ứng dụng kỹ thuật học sâu trong hệ gợi ý: Học tương phản

# Lọc cộng tác (collaborative filtering)



# Nội dung

- Ôn tập các kỹ thuật học máy
- Lọc cộng tác dựa trên các mô hình học máy cơ bản
- Lọc cộng tác dựa trên mô hình học sâu để học biểu diễn ẩn
- Dữ liệu phản hồi tiềm ẩn và rõ ràng (implicit và explicit feedback)
- Tài liệu tham khảo

# Lọc cộng tác

- Input
  - Only a matrix of given user–item ratings
- Output types
  - A (numerical) prediction indicating to what degree the current user will like or dislike a certain item
  - A top-N list of recommended items

# 1. Ôn tập các kỹ thuật học máy

- Các phương pháp Naïve Bayes, cây quyết định (decision tree), mạng nơ-ron nhân tạo (neural networks)

# 2. Lọc cộng tác dựa trên các phương pháp học máy cơ bản

- Ý tưởng:
  - Biểu diễn user là các vector mà mỗi chiều là các items
  - Mỗi thuộc tính (item) đều có thể là thuộc tính nhãn
  - Xây dựng bộ phân loại theo mỗi thuộc tính nhãn để dự đoán giá trị của user cho item tương ứng
  - Số lượng bộ phân loại bằng số lượng items

# Lọc cộng tác dựa trên Naïve Bayes (1)

- Áp dụng khi dữ liệu user-item feedback rời rạc (có thể mở rộng với user-item feedback liên tục với Gaussian Naïve Bayes)
- Xem xét user như data instance với các features là items
- Khác biệt với Naïve Bayes truyền thống: Bất kỳ feature nào cũng có thể là label.

| | Item1 | Item2 | Item3 | Item4 | Item5 |
|---|---|---|---|---|---|
| Alice | 5 | 3 | 4 | 4 | ? |
| User1 | 3 | 1 | 2 | 3 | 3 |
| User2 | 4 | 3 | 4 | 3 | 5 |
| User3 | 3 | 3 | 1 | 5 | 4 |
| User4 | 1 | 5 | 5 | 2 | 1 |

# Lọc cộng tác dựa trên Naïve Bayes (2)

- Miền giá trị của rating: Gồm $l$ giá trị rời rạc $\{ v_1, \dots, v_l \}$
- Mỗi user $u$ sẽ có tập $I_u$ các items đã rate
- Dự đoán giá trị rating $r_{uj}$ của user $u$ cho item $j$
- Tính xác suất:

$$P(r_{uj} = v_s | Observed\ ratings\ in\ I_u)$$
$$= \frac{P(r_{uj} = v_s)\ P(Observed\ ratings\ in\ I_u | r_{uj} = v_s)}{P(Observed\ ratings\ in\ I_u)}$$

trong đó: $s \in \{1, \dots, l\}$

- Chỉ cần tính các đại lượng trên tử số, mẫu số đóng vai trò như thành phần để chuẩn hóa.

$$P(Observed\ ratings\ in\ I_u) = \sum_{s=1}^{l} P(r_{uj} = v_s, Observed\ ratings\ in\ I_u)$$

# Lọc cộng tác dựa trên Naïve Bayes (3)

- $P(r_{uj} = v_s)$ được xem như xác suất tiên nghiệm
- $P(Observed\ ratings\ in\ I_u | r_{uj} = v_s)$ được xem như xác suất likelihood
- Giả thiết độc lập có điều kiện:

$$P(Observed\ ratings\ in\ I_u | r_{uj} = v_s) = \prod_{k \in I_u} P(r_{uk} | r_{uj} = v_s)$$

- Chúng ta thu được:

$$P(r_{uj} = v_s)\ P(Observed\ ratings\ in\ I_u | r_{uj} = v_s)$$

$$= P(r_{uj} = v_s) \prod_{k \in I_u} P(r_{uk} | r_{uj} = v_s)$$

- Tính các đại lượng trên tử số dựa vào dữ liệu training set

# Lọc cộng tác dựa trên Naïve Bayes (4)

- Dự đoán:

$$\bar{r}_{uj} = \frac{\sum_{s=1}^{l} v_s \,.\, P(r_{uj} = v_s) \,.\, P(Observed\ ratings\ in\ I_u | r_{uj} = v_s)}{\sum_{s=1}^{l} P(r_{uj} = v_s) \,.\, P(Observed\ ratings\ in\ I_u | r_{uj} = v_s)}$$

$$= \frac{\sum_{s=1}^{l} v_s \,.\, P(r_{uj} = v_s) \,.\, \prod_{k \in I_u} P(r_{uk} | r_{uj} = v_s)}{\sum_{s=1}^{l} P(r_{uj} = v_s) \,.\, \prod_{k \in I_u} P(r_{uk} | r_{uj} = v_s)}$$

- Chú ý thống kê $P(v_s)$ và $P(v_k | r_{uj} = v_s)$ theo thuộc tính j trên toàn bộ dữ liệu training

# Lọc cộng tác dựa trên cây quyết định, mạng nơ-ron

- Ý tưởng tương tự với Naïve Bayes
- Xem xét user như data instance với các features là items
- Khác biệt với mô hình truyền thống: Bất kỳ feature nào cũng có thể là label.
- Phải xây dựng số lượng cây quyết định hoặc mạng nơ-ron nhân tạo  bằng số lượng items

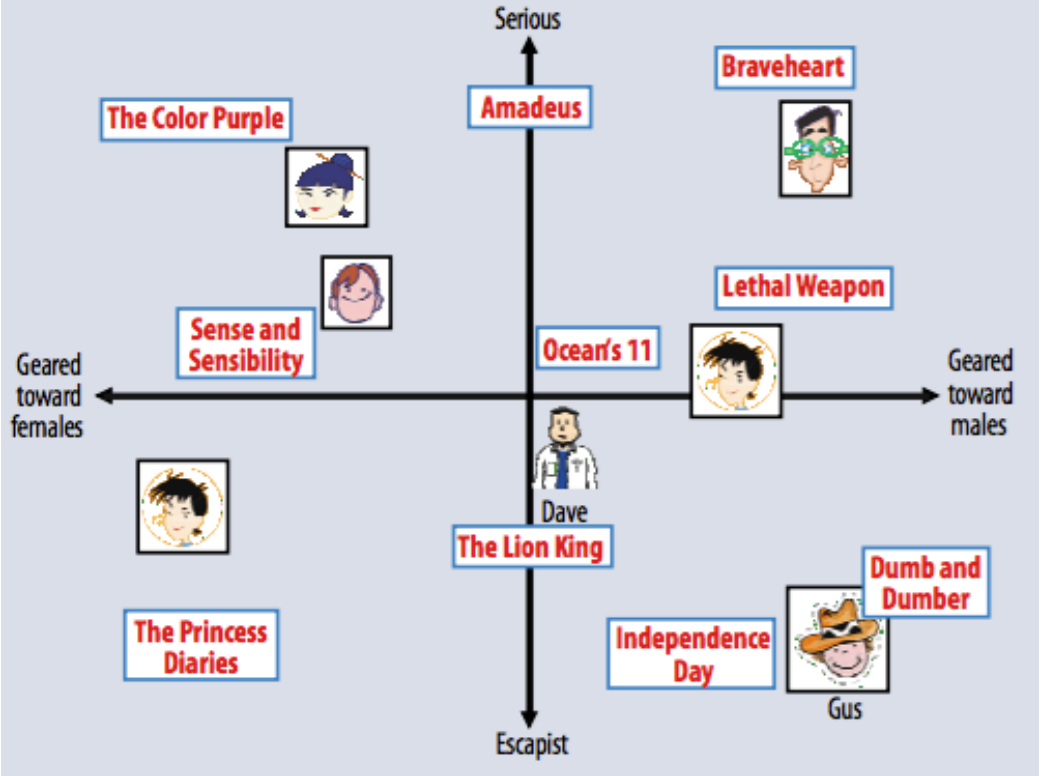
| | Item1 | Item2 | Item3 | Item4 | Item5 |
|---|---|---|---|---|---|
| Alice | 5 | 3 | 4 | 4 | ? |
| User1 | 3 | 1 | 2 | 3 | 3 |
| User2 | 4 | 3 | 4 | 3 | 5 |
| User3 | 3 | 3 | 1 | 5 | 4 |
| User4 | 1 | 5 | 5 | 2 | 1 |

# 3. Lọc cộng tác nâng cao: Học biểu diễn ẩn

- Phân tích ma trận (matrix factorization) được sử dụng để học biểu diễn cho mỗi user và item
- Phân tích ma trận được có thể xem là một mạng nơ-ron nhân tạo đơn giản
- Một số cách khác dựa trên sử dụng học sâu trong phân tích ma trận
  - Neural matrix factorization [He et.al 2017]
  - Deep matrix factorization [Xue et.al. 2017]
  - LightGCN [He et.al 2020]

# Nhắc lại: Phân tích ma trận

- Phân tích ma trận được sử dụng để học biểu diễn user và item trên cùng không gian biểu diễn




Figures from Koren et al. (2009)

# Phân tích ma trận

- Biểu diễn của user u:

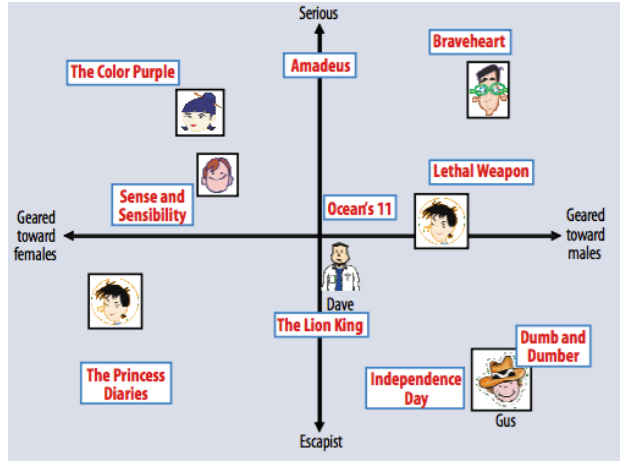
$$(W_{u*})^T \in \mathbb{R}^r$$

- Biểu diễn của item i:

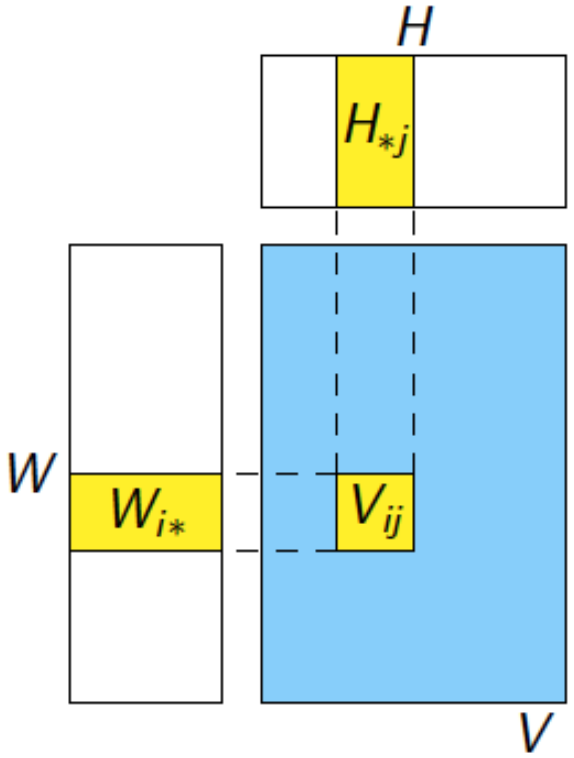
$$H_{*i} \in \mathbb{R}^r$$

- Rating của user u cho item i:

$$V_{ui} = W_{u*}H_{*i}$$
$$= [WH]_{ui}$$




Figures from Koren et al. (2009)




Figures from Gemulla et al. (2011)

# Phân tích ma trận

- User vectors:

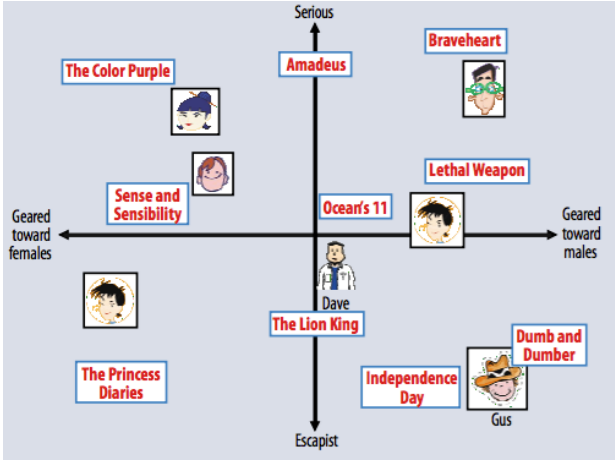
$$\mathbf{w}_u \in \mathbb{R}^r$$

- Item vectors:

$$\mathbf{h}_i \in \mathbb{R}^r$$

- Dự đoán Rating:

$$v_{ui} = \mathbf{w}_u^T \mathbf{h}_i$$




Figures from Koren et al. (2009)

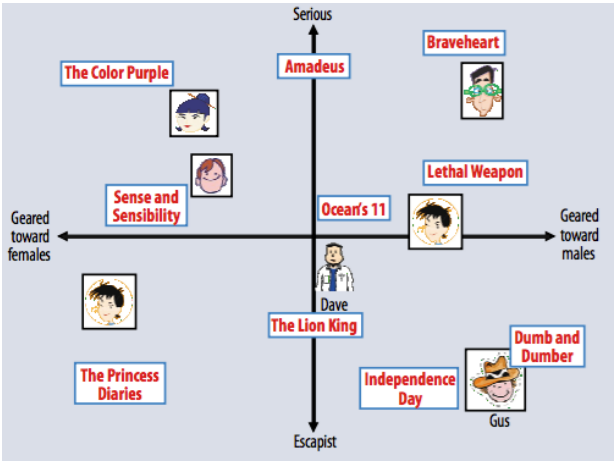
# Phân tích ma trận

- Dữ liệu huấn luyện: Z là tập các cặp user-item có tương tác:

$$\mathcal{Z} = \{(u, i) : v_{ui} \neq 0\}$$

- Hàm mục tiêu:

$$\underset{\mathbf{w},\mathbf{h}}{\operatorname{argmin}} \sum_{(u,i)\in\mathcal{Z}} (v_{ui} - \mathbf{w}_u^T \mathbf{h}_i)^2$$

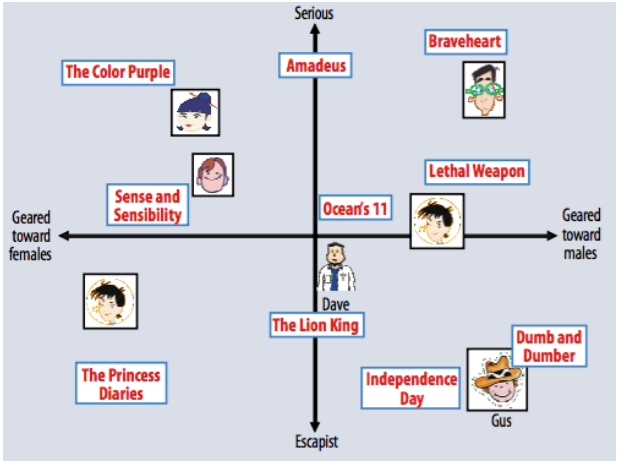



Figures from Koren et al. (2009)

# Phân tích ma trận

- Hàm mục tiêu với đại lượng hiệu chỉnh :

$$\underset{\mathbf{w},\mathbf{h}}{\operatorname{argmin}} \sum_{(u,i)\in\mathcal{Z}} (v_{ui} - \mathbf{w}_u^T \mathbf{h}_i)^2 + \lambda(\sum_i ||\mathbf{w}_i||^2 + \sum_u ||\mathbf{h}_u||^2)$$

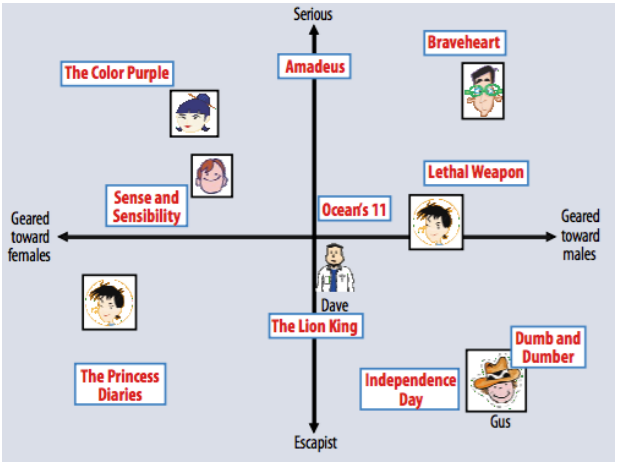



Figures from Koren et al. (2009)

# Phân tích ma trận

- Hàm mục tiêu:

$$\underset{\mathbf{w},\mathbf{h}}{\operatorname{argmin}} \sum_{(u,i)\in\mathcal{Z}} (v_{ui} - \mathbf{w}_u^T \mathbf{h}_i)^2 + \lambda(\sum_i ||\mathbf{w}_i||^2 + \sum_u ||\mathbf{h}_u||^2)$$




Figures from Koren et al. (2009)

- Sử dụng SGD (stochastic gradient descent) để học:

$$e_{ui} \leftarrow v_{ui} - \mathbf{w}_u^T \mathbf{h}_i$$
$$\mathbf{w}_u \leftarrow \mathbf{w}_u + \gamma(e_{ui}\mathbf{h}_i - \lambda \mathbf{w}_u)$$
$$\mathbf{h}_i \leftarrow \mathbf{h}_i + \gamma(e_{ui}\mathbf{w}_u - \lambda \mathbf{h}_i)$$

# Phân tích ma trận: Góc nhìn của mạng nơ-ron

Mô hình Generalized Matrix factorization

- Đầu vào: vector one-hot mã hóa định danh cho user, item.
- Tầng embedding biểu diễn u, i:

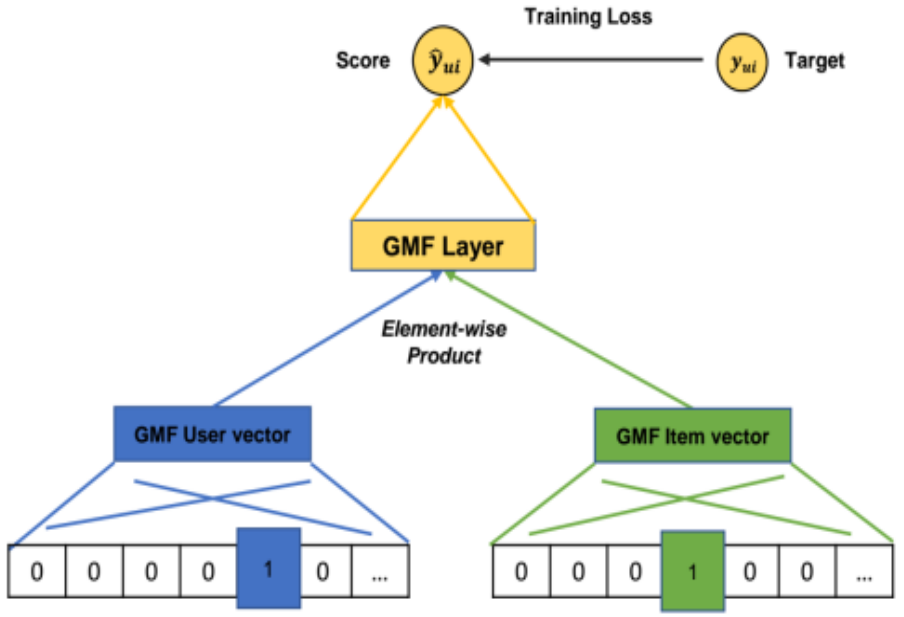
$$\mathbf{p}_u = \mathbf{P}^T\mathbf{u} \qquad \mathbf{q}_i = \mathbf{Q}^T\mathbf{i}$$

- Hàm kết hợp:

$$\phi_1(\mathbf{p}_u, \mathbf{q}_i) = \mathbf{p}_u \odot \mathbf{q}_i$$

- Đầu ra mô hình:

$$\hat{y}_{ui} = a_{out}(\mathbf{h}^T(\mathbf{p}_u \odot \mathbf{q}_i))$$



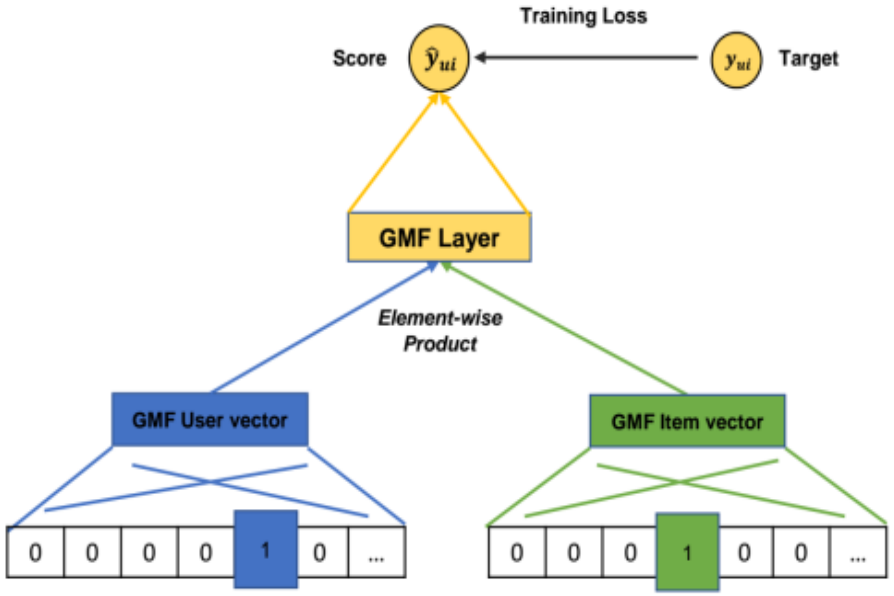

Generalized Matrix Factorization

# Phân tích ma trận: Góc nhìn của mạng nơ-ron

- Trọng số h: mô tả được mức độ quan trọng khác nhau của các thuộc tính ẩn.

$$\hat{y}_{ui} = a_{out}(\mathbf{h}^T(\mathbf{p}_u \odot \mathbf{q}_i))$$

- $a_{out}$ là hàm đồng nhất, các trọng số trong h đều bằng 1 => MF.
- $a_{out}$ có thể là hàm phi tuyến (sigmoid,..) thu được mô hình MF phi tuyến.




Generalized Matrix Factorization

# Multi-layer Perceptron Matrix Factorization

- Đầu vào là vector one-hot

$$\mathbf{z_1} = \phi_1(\mathbf{p}_u, \mathbf{q}_i) = \begin{bmatrix} \mathbf{p}_u \\ \mathbf{q}_i \end{bmatrix}$$

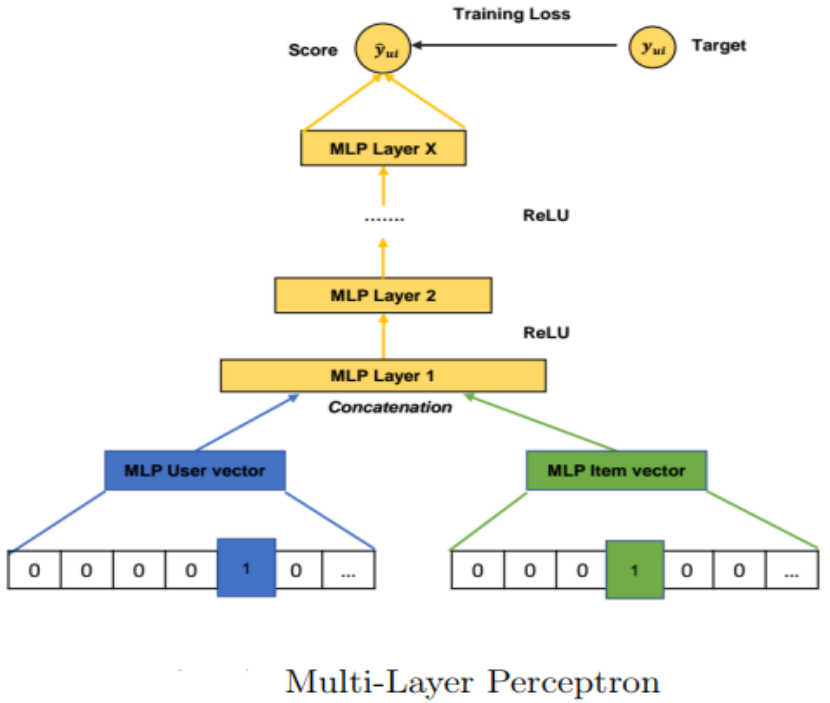
$$\mathbf{z_2} = \phi_2(\mathbf{z_1}) = a_2(\mathbf{z_1}\mathbf{W_2} + \mathbf{b_2})$$

$$\dots$$

$$\mathbf{z_X} = \phi_X(\mathbf{z_{X-1}}) = a_X(\mathbf{z_{X-1}}\mathbf{W_X} + \mathbf{b_X})$$

$$\hat{y}_{ui} = a_{out}(\mathbf{h}^T\mathbf{z_X})$$

  - $a_x$ , $W_x$, $b_x$ : là hàm kích hoạt, ma trận trọng số, bias của tầng thứ x.
  - Sử dụng ReLU làm hàm kích hoạt.




Multi-Layer Perceptron

# Neural Matrix Factorization (NeuMF)

- Kết hợp 2 mô hình GMF, MLP:
  - GMF: mô hình tuyến tính.
  - MLP: mô hình phi tuyến.
- Sử dụng tầng embedding riêng cho mỗi mô hình.




Neural Matrix Fatorization

# Neural Matrix Factorization

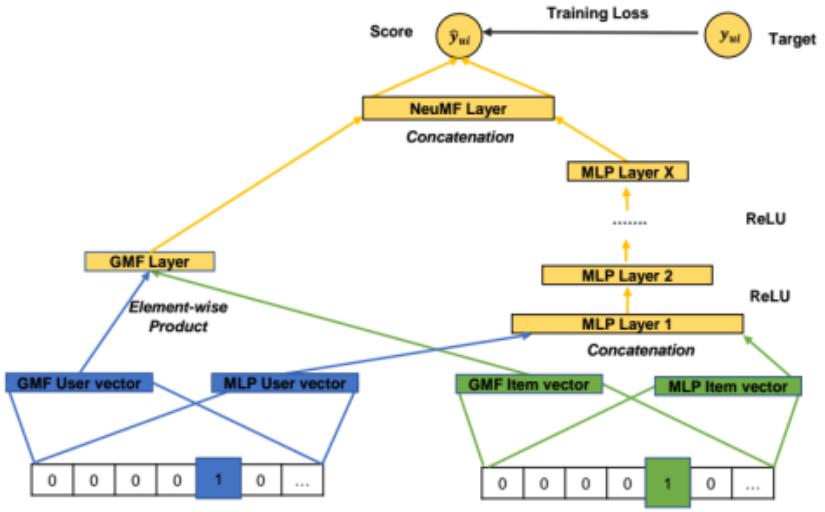
- Sử dụng tầng embedding riêng cho mỗi mô hình và tổ hợp lại:

$$\phi^{GMF} = \mathbf{p}_u^G \odot \mathbf{q}_i^G,$$

$$\phi^{MLP} = a_X(\mathbf{W}_X^T(a_{X-1}(...a_2(\mathbf{W}_2^T \begin{bmatrix} \mathbf{p}_u^M \\ \mathbf{q}_i^M \end{bmatrix} + \mathbf{b}_2)...)) + \mathbf{b}_X),$$

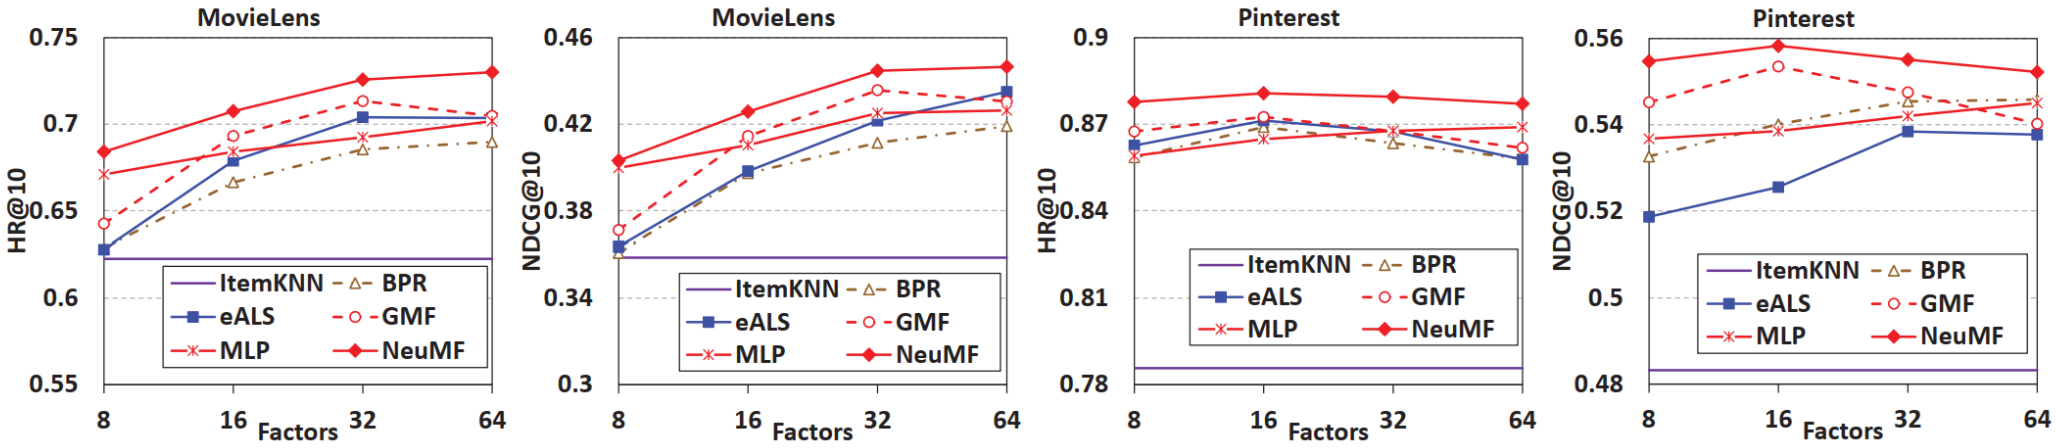
$$\hat{y}_{ui} = a_{out}(\mathbf{h}^T \begin{bmatrix} \phi^{GMF} \\ \phi^{MLP} \end{bmatrix})$$

- $p_u^G$ , $p_u^M$ :vector thuộc tính ẩn của u trong GMF, MLP
- $q_i^G$ , $q_i^M$ :vector thuộc tính ẩn của item i.
- $a_{out}$ : sử dụng hàm sigmoid.



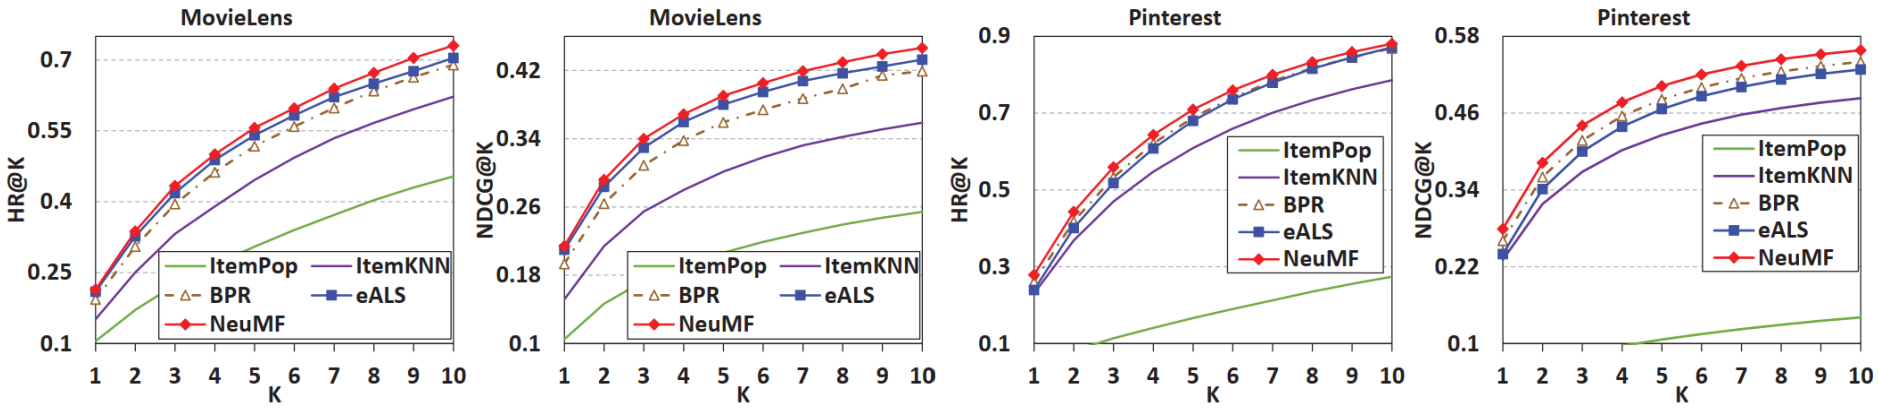

Neural Matrix Fatorization

# Minh họa kết quả: NeuMF

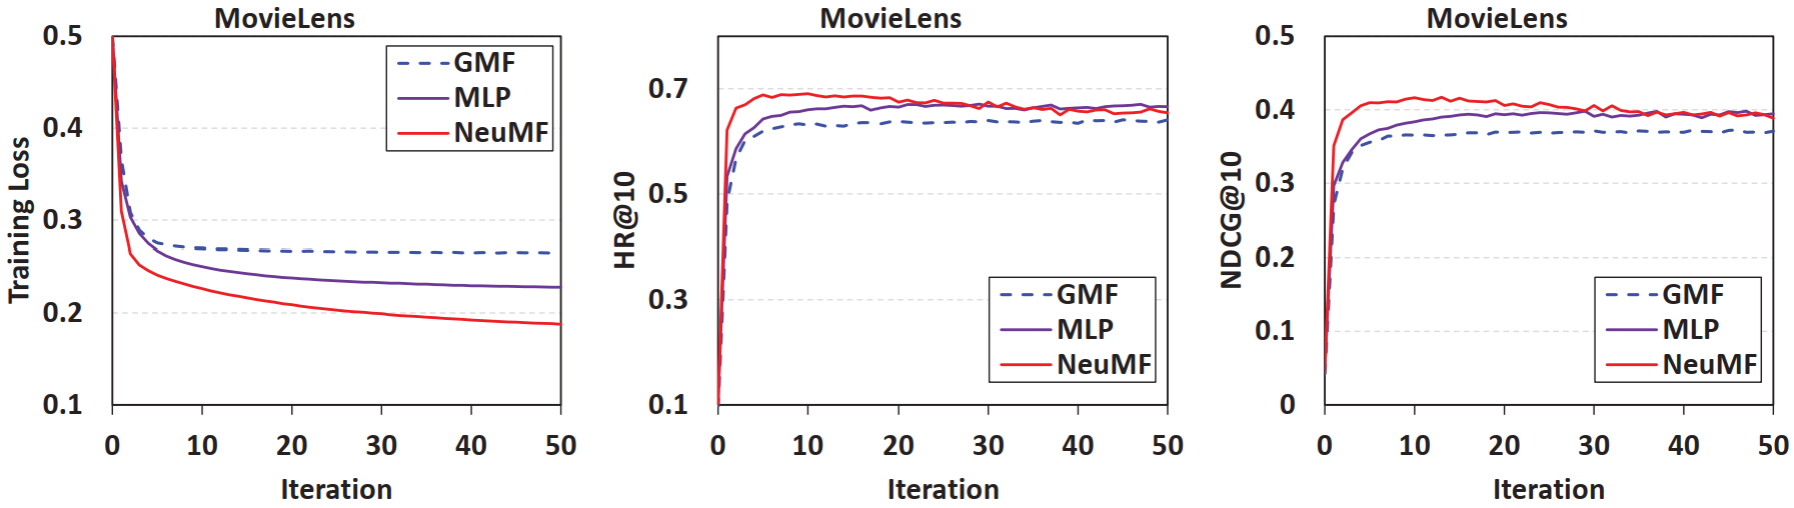



(a) MovieLens — HR@10 (b) MovieLens — NDCG@10 (c) Pinterest — HR@10 (d) Pinterest — NDCG@10

# Minh họa kết quả: NeuMF



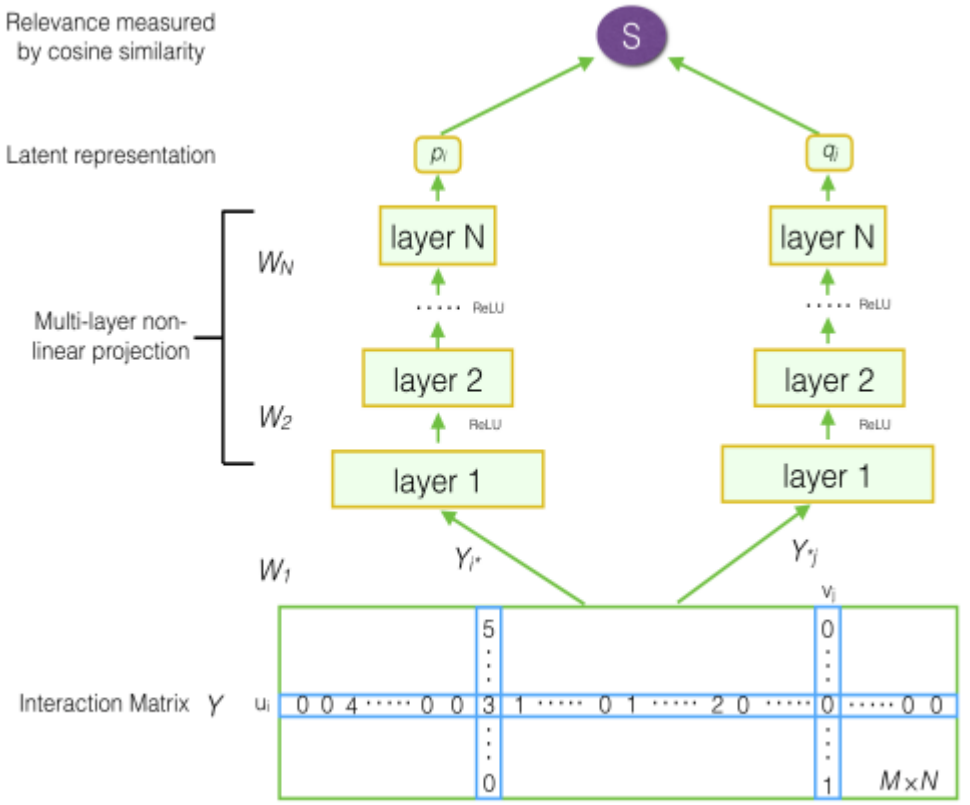

(a) MovieLens — HR@K (b) MovieLens — NDCG@K (c) Pinterest — HR@K (d) Pinterest — NDCG@K




(a) Training Loss (b) HR@10 (c) NDCG@10

# Deep Matrix Factorization

- Biểu diễn user là vector của các item
- Biểu diễn item là vector của các user
- Sử dụng mạng MLP để học các tầng biểu diễn của user và item
- Kết hợp biểu diễn của user và item để đưa ra điểm phù hợp




Deep matrix factorization

# Minh họa kết quả: DMF

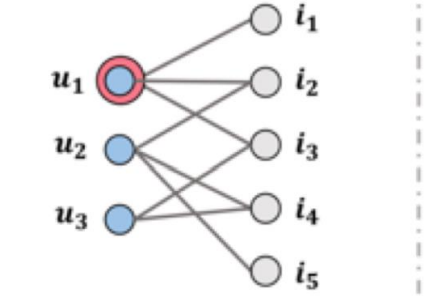
| Datasets | Metrics | Methods | | | | DMF | |
|---|---|---|---|---|---|---|---|
| | | ItemPop | ItemKNN | eALS | NeuMF-p | DMF-2-ce | DMF-2-nce |
| ML100k | NDCG | 0.231 | 0.334 | 0.356 | 0.395 | 0.405 | 0.409 |
| | HR | 0.406 | 0.600 | 0.621 | 0.670 | 0.679 | 0.687 |
| ML1m | NDCG | 0.263 | 0.372 | 0.425 | 0.440 | 0.442 | 0.451 |
| | HR | 0.472 | 0.637 | 0.709 | 0.722 | 0.720 | 0.732 |
| Amusic | NDCG | 0.242 | 0.345 | 0.374 | 0.371 | 0.403 | 0.397 |
| | HR | 0.423 | 0.493 | 0.521 | 0.527 | 0.570 | 0.563 |
| Amovie | NDCG | 0.386 | 0.403 | 0.455 | 0.512 | 0.533 | 0.550 |
| | HR | 0.620 | 0.652 | 0.693 | 0.739 | 0.765 | 0.773 |

# LightGCN (He et.al 2020)

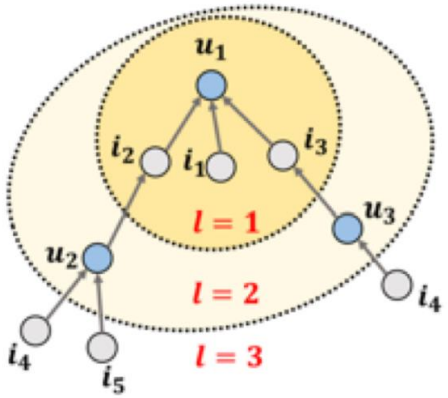
- Tương tác của user-item có thể biểu diễn thành đồ thị 2 phía (user-item bipartite graph).
- Sử dụng đồ thị có thể bắt được tương tác bậc cao hơn (high-order connectivity)

E.g., why $u_1$ may like $i_4$?

- $u_1 \leftarrow i_2 \leftarrow u_2 \leftarrow i_4$
- $u_1 \leftarrow i_3 \leftarrow u_3 \leftarrow i_4$




User-Item Interaction Graph




High-order Connectivity for $u_1$

# Graph convolutional network (GCN)

- Mạng đồ thị tích GCN là một công cụ hiệu quả để học biểu diễn cho dữ liệu dạng đồ thị.
- Xem xét một đồ thị $G = (V, E)$ trong đó $V$ là tập các đỉnh và $E$ là tập cạnh của đồ thị.
- Đặt $A$ ($A \in R^{V \times V}$) là ma trận kề của đồ thị $G$ và $X$ ($X \in R^{V \times M}$) là ma trận biểu diễn cho các đỉnh mà mỗi hàng $X_i$ ($i \in \{1, \ldots, V\}$) là một vectơ $M$-chiều biểu diễn cho đỉnh thứ $i$.
- Mạng đồ thị tích chập học $L$ tầng biểu diễn ẩn của các đỉnh trong đồ thị
- Biểu diễn của các đỉnh $h_l$ ở tầng thứ $l$ được tính thông qua lần lượt hai bước: Bước tổng hợp (aggregation) và biến đổi (transformation).

# Graph convolutional network (GCN)

- Tại bước tổng hợp, biểu diễn của một đỉnh được tổng hợp từ biểu diễn của các đỉnh có cạnh nối với nó và thông tin từ chính đỉnh đó.

$$\bar{h}_l = \widetilde{D}^{-\frac{1}{2}}\tilde{A}\widetilde{D}^{-\frac{1}{2}}h_{l-1}$$

- Sau đó, bước biến đổi cho phép chuyển đổi biểu diễn của các đỉnh.

$$h_l = f(\bar{h}_l W_l)$$

- trong đó, $\tilde{A} = A + I_V$ ($I_V$ là ma trận đơn vị), $\tilde{D}_{ii} = \sum_j \tilde{A}_{ij}$, $W_l$ là ma trận trọng số của tầng thứ $l$, $h_0 = X$ và hàm hoạt động $f$ là hàm ReLU.
- Chúng ta có thể gộp 2 bước:

$$h_l = f\left(\widetilde{D}^{-\frac{1}{2}}\tilde{A}\widetilde{D}^{-\frac{1}{2}}h_{l-1}W_l\right)$$

Có thể đặt thêm bias:

$$h_l = f\left(\widetilde{D}^{-\frac{1}{2}}\tilde{A}\widetilde{D}^{-\frac{1}{2}}(h_{l-1}W_l + b_l)\right)$$

# Sử dụng GCN cho lọc cộng tác

- Xây dựng đồ thị đỉnh là user và item, cạnh là tương tác của user-item
- Sử dụng mạng GCN để học biểu diễn cho các đỉnh là user (U) và item (I)

$$(U, I) = GCN(User - item\ graph)$$

- Mức độ yêu thích của user j cho item v được tính như sau:

$$R_{jv} = U_j^T I_v$$

# LightGCN

- LightGCN dựa vào thực nghiệm để đưa ra một số lược giảm của GCN gốc cho gợi ý:
  - Loại bỏ biến đổi phi tuyến
  - Không sử dụng activation phi tuyến
  - Loại bỏ liên kết tự kết nối của đỉnh tới chính nó

# LightGCN

- LightGCN thực hiện các bước như sau:
  - Lấy thông tin láng giềng

$$\mathbf{e}_u^{(k+1)} = \sum_{i \in \mathcal{N}_u} \frac{1}{\sqrt{|\mathcal{N}_u|}\sqrt{|\mathcal{N}_i|}} \mathbf{e}_i^{(k)},$$

$$\mathbf{e}_i^{(k+1)} = \sum_{u \in \mathcal{N}_i} \frac{1}{\sqrt{|\mathcal{N}_i|}\sqrt{|\mathcal{N}_u|}} \mathbf{e}_u^{(k)}.$$

  - Kết hợp tuyến tính  biểu diễn các layers k

$$\mathbf{e}_u = \sum_{k=0}^{K} \alpha_k \mathbf{e}_u^{(k)}; \quad \mathbf{e}_i = \sum_{k=0}^{K} \alpha_k \mathbf{e}_i^{(k)},$$

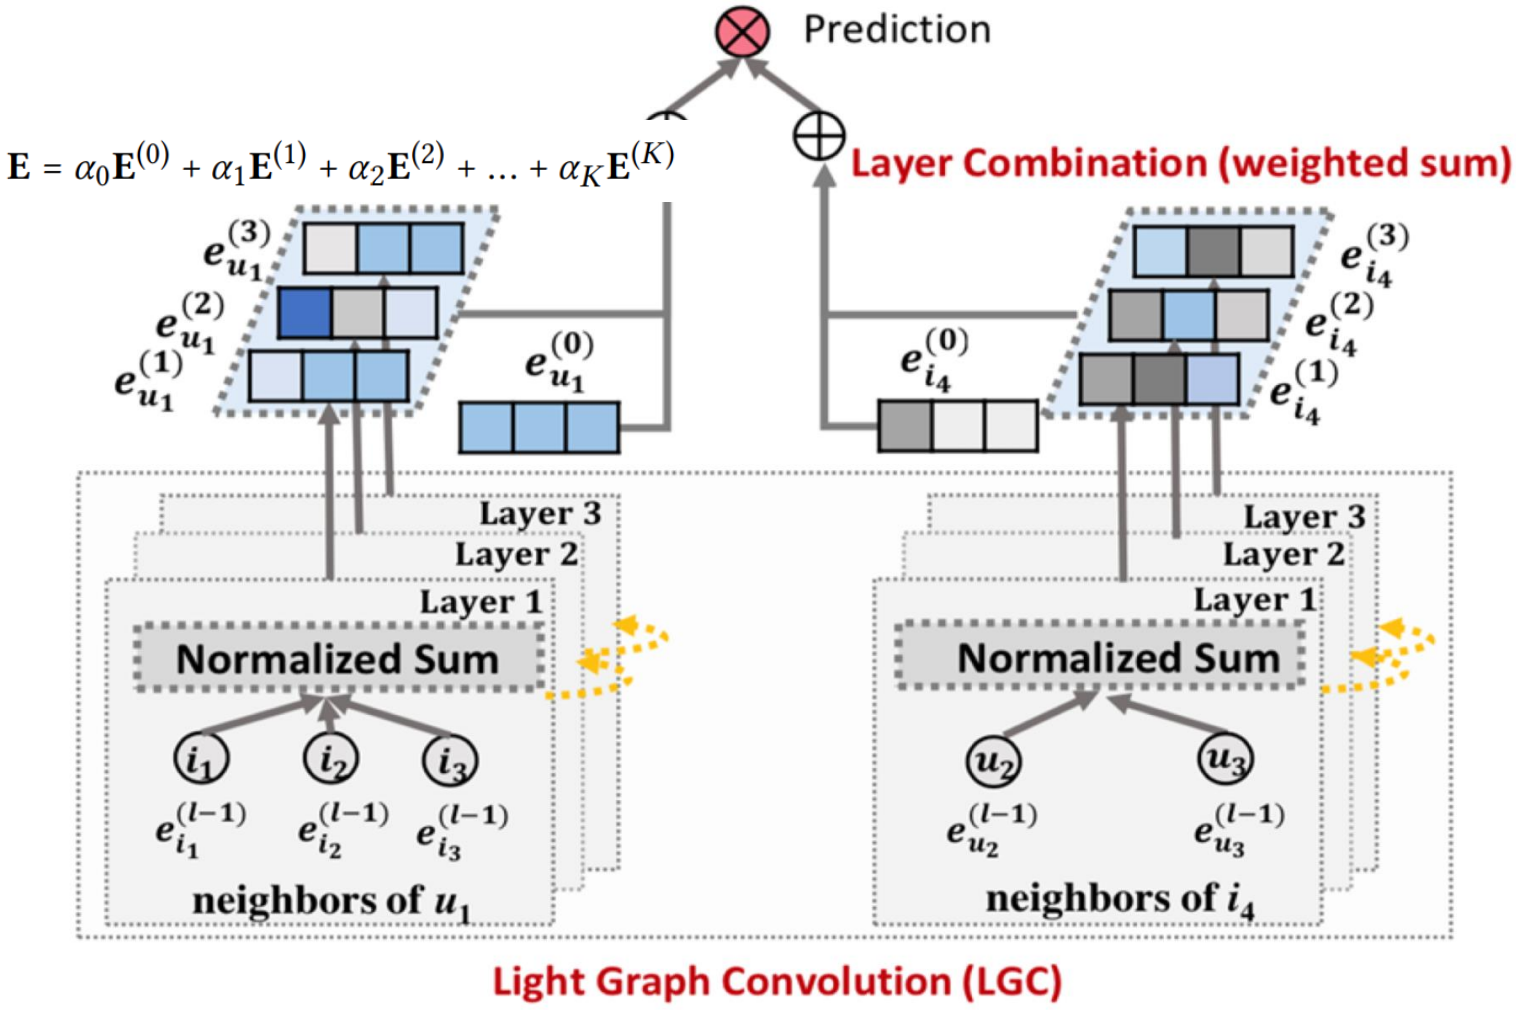
  - Loại bỏ liên kết tự kết nối của đỉnh tới chính nó

$$\mathbf{E}^{(k+1)} = (\mathbf{D}^{-\frac{1}{2}}\mathbf{A}\mathbf{D}^{-\frac{1}{2}})\mathbf{E}^{(k)}$$

  - Với R là interaction matrix và

$$\mathbf{A} = \begin{pmatrix} \mathbf{0} & \mathbf{R} \\ \mathbf{R}^T & \mathbf{0} \end{pmatrix}$$

# LightGCN


Prediction
$\mathbf{E} = \alpha_0\mathbf{E}^{(0)} + \alpha_1\mathbf{E}^{(1)} + \alpha_2\mathbf{E}^{(2)} + \ldots + \alpha_K\mathbf{E}^{(K)}$
Layer Combination (weighted sum)
$e_{u_1}^{(3)}$
$e_{u_1}^{(2)}$
$e_{u_1}^{(1)}$
$e_{u_1}^{(0)}$
$e_{i_4}^{(0)}$
$e_{i_4}^{(3)}$
$e_{i_4}^{(2)}$
$e_{i_4}^{(1)}$
Layer 3
Layer 2
Layer 1
Normalized Sum
$i_1$ $i_2$ $i_3$
$e_{i_1}^{(l-1)}$ $e_{i_2}^{(l-1)}$ $e_{i_3}^{(l-1)}$
neighbors of $u_1$
Layer 3
Layer 2
Layer 1
Normalized Sum
$u_2$ $u_3$
$e_{u_2}^{(l-1)}$ $e_{u_3}^{(l-1)}$
neighbors of $i_4$
Light Graph Convolution (LGC)

# Minh họa hiệu quả: LightGCN

**Table 2: Statistics of the experimented data.**

| Dataset | User # | Item # | Interaction # | Density |
|---|---|---|---|---|
| Gowalla | 29, 858 | 40, 981 | 1, 027, 370 | 0.00084 |
| Yelp2018 | 31, 668 | 38, 048 | 1, 561, 406 | 0.00130 |
| Amazon-Book | 52, 643 | 91, 599 | 2, 984, 108 | 0.00062 |

| Dataset | Gowalla | | Yelp2018 | | Amazon-Book | |
|---|---|---|---|---|---|---|
| **Method** | **recall** | **ndcg** | **recall** | **ndcg** | **recall** | **ndcg** |
| NGCF | 0.1570 | 0.1327 | 0.0579 | 0.0477 | 0.0344 | 0.0263 |
| Mult-VAE | 0.1641 | 0.1335 | 0.0584 | 0.0450 | 0.0407 | 0.0315 |
| GRMF | 0.1477 | 0.1205 | 0.0571 | 0.0462 | 0.0354 | 0.0270 |
| GRMF-norm | 0.1557 | 0.1261 | 0.0561 | 0.0454 | 0.0352 | 0.0269 |
| LightGCN | **0.1830** | **0.1554** | **0.0649** | **0.0530** | **0.0411** | **0.0315** |

# 4. Dữ liệu explicit và implicit feedback

- Dữ liệu explicit feedback (ratings, purchas, like)
  - Dữ liệu quý giá, thể hiện sở thích của user
  - Thưa, ít, khó thu thập
  - Khó khăn khi học các mô hình
- Dữ liệu implicit feedback (click, view)
  - Dữ liệu nhiều, dễ thu thập
  - Phản ánh tiềm ẩn mức độ ưa thích của người dùng
  - Có thể có nhiễu

# Weighted Matrix Factorization

- Weighted Matrix Factorization (Yifan Hu el at -2008)
- Dữ liệu tiềm ẩn: số lần xem một video, thời lượng xem một video, lịch sử mua sắm,… của người dùng.
  - ❖ Dữ liệu tương tác tường minh cho ta biết sở thích người dùng (like, dislike). Tương tác ẩn, dữ liệu tương tác tiềm ẩn thì đều là các phản hồi tích cực.
    - ➢ VD: $r_{ui}$ cho biết số lần u xem toàn bộ một bộ phim i. Khi $r_{ui}$ = 0.7, tức u đã xem 70% video.
    - ➢ Các tương tác tiềm ẩn có các mức độ khác nhau.

# Weighted Matrix Factorization

- Sử dụng có dữ liệu implicit
  - ❖ Đưa dữ liệu tiềm ẩn về dạng tương tác nhị phân:

$$p_{ui} = \begin{cases} 1 & r_{ui} > 0 \\ 0 & r_{ui} = 0 \end{cases}$$

  - ❖ Dữ liệu tiềm ẩn có các mức độ khác nhau, sử dụng trọng số thể hiện độ tin cậy:

$$c_{ui} = 1 + \alpha r_{ui}$$

  - ❖ Hàm mục tiêu:

$$\min_{x_\star, y_\star} \sum_{u,i} c_{ui}(p_{ui} - x_u^T y_i)^2 + \lambda \left( \sum_u \|x_u\|^2 + \sum_i \|y_i\|^2 \right)$$

  - ❖Công thức nghiệm (hồi quy tuyến tính):

$$x_u = (Y^T C^u Y + \lambda I)^{-1} Y^T C^u p(u)$$

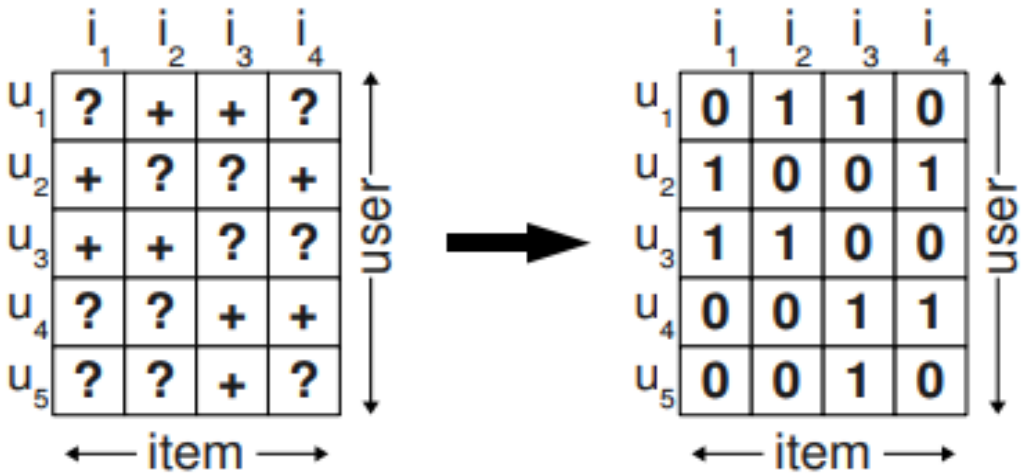
$$y_i = (X^T C^i X + \lambda I)^{-1} X^T C^i p(i)$$

# Bayesian Personalized Ranking

- Bayesian Personalized Ranking (Rendle el at -2009)
- Đưa ra một danh sách có xếp hạng các sản phẩm cho mỗi người dùng.
  - ❖ Thứ tự này có thể suy ra từ nhóm hành vi tiềm ẩn của người dùng.
  - ❖ Tiếp cận theo cặp item, khác so với phương pháp MF truyền thống.
  - ❖ Dữ liệu tiềm ẩn:
    - Dữ liệu quan sát được là positive.
    - Các cặp user-item không quan sát được: có thể thực sự không thích (negative), chưa biết (missing value).

# Bayesian Personalized Ranking

- MF truyền thống: Dự đoán giá trị $\hat{x}_{ui}$ thể hiện mức độ ưa thích của u cho i.



# Bayesian Personalized Ranking

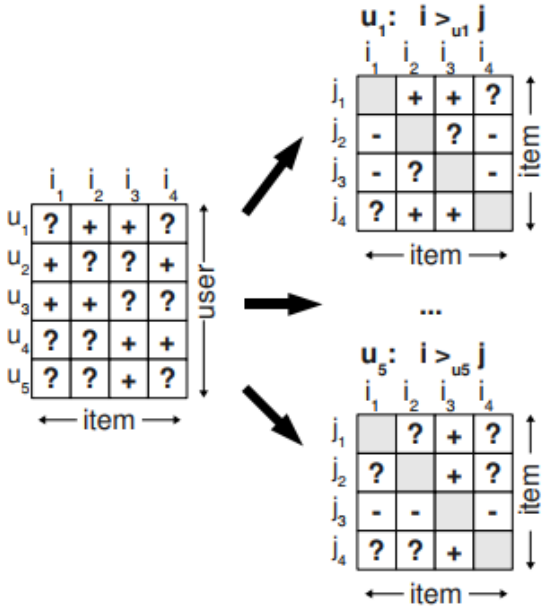
Mối quan hệ thứ tự $i >_u j$ giữa các cặp sản phẩm:

- (+): u ưa thích sản phẩm i hơn j.
- (-): u ưa thích sản phẩm j hơn i.

❖ Mỗi u, xác định thứ tự sản phẩm theo thứ tự sẽ được yêu thích bởi u. Xác suất hậu nghiệm:

Θ: tham số của mô hình.

$$p(\Theta|i >_u j) \propto p(i >_u j|\Theta)p(\Theta)$$



# Bayesian Personalized Ranking

- Sử dụng hàm sigmoid để mô hình hóa xác suất u thích sản phẩm i hơn j.

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

❖ $r_{uij}$ mô tả sự khác nhau giữa dự đoán cho sản phẩm và sản phẩm j:

$$p(i >_u j|\Theta) = \sigma\left(\hat{r}_{uij}(\Theta)\right)$$

$$\hat{r}_{uij} = \hat{r}_{ui} - \hat{r}_{uj}$$

$$= x_u y_i^T - x_u y_j^T$$

# Bayesian Personalized Ranking (Rendle el at -2009)

- Hàm mục tiêu

$$
\begin{aligned}
BPR-Opt &= \prod_{u,i,j} p(i >_u j|\Theta)p(\Theta) \\
&= ln(\prod_{u,i,j} p(i >_u j|\Theta)p(\Theta)) \\
&= \sum_{u,i,j} ln\sigma(\hat{r}_{ui} - \hat{r}_{uj}) + lnp(\Theta) \\
&= \sum_{u,i,j} ln\sigma(\hat{r}_{ui} - \hat{r}_{uj}) - \lambda_\Theta \|\Theta\|^2 \\
&= \sum_{u,i,j} ln\sigma(\hat{r}_{ui} - \hat{r}_{uj}) - \frac{\lambda_\Theta}{2}\|x_u\|^2 - \frac{\lambda_\Theta}{2}\|y_i\|^2 - \frac{\lambda_\Theta}{2}\|y_j\|^2 \\
&= \sum_{u,i,j} ln\sigma(x_u y_i^T - x_u y_j^T) - \frac{\lambda_\Theta}{2}\|x_u\|^2 - \frac{\lambda_\Theta}{2}\|y_i\|^2 - \frac{\lambda_\Theta}{2}\|y_j\|^2 \\
&= \sum_{u,i,j} ln\frac{1}{1+e^{-(x_u y_i^T - x_u y_j^T)}} - \frac{\lambda_\Theta}{2}\|x_u\|^2 - \frac{\lambda_\Theta}{2}\|y_i\|^2 - \frac{\lambda_\Theta}{2}\|y_j\|^2
\end{aligned}
$$

# Bayesian Personalized Ranking

- Loss:

$$argmin_{x_u,y_i,y_j} \sum_{u,i,j} -ln \frac{1}{1+e^{-(x_u y_i^T - x_u y_j^T)}} + \frac{\lambda_\Theta}{2}\|x_u\|^2 + \frac{\lambda_\Theta}{2}\|y_i\|^2 + \frac{\lambda_\Theta}{2}\|y_j\|^2$$

❖ Cập nhật tham số:

$$\frac{\partial}{\partial x_u} = \frac{1}{1+e^{(x_u y_i^T - x_u y_j^T)}} \cdot (y_j - y_i) + \lambda x_u$$

$$\frac{\partial}{\partial y_i} = \frac{1}{1+e^{(x_u y_i^T - x_u y_j^T)}} \cdot -x_u + \lambda y_i$$

$$\frac{\partial}{\partial y_j} = \frac{1}{1+e^{(x_u y_i^T - x_u y_j^T)}} \cdot x_u + \lambda y_j$$

# Sử dụng đồng thời Implicit và explicit feedback

- Co-rating [Nathan et al 2010]: Sử dụng cả dữ liệu implicit Y và explicit X:

$$\arg\min_{U,V} \mathcal{L}_E(U,V) + \eta \cdot \mathcal{L}_I(U,V) + \lambda \cdot \mathcal{R}(U,V)$$

$$\mathcal{L}_E(U,V) = \sum_{(u,i)\in S^*} (x_{ui} - \mathbf{u}_i^\top \mathbf{v}_u)^2$$

$$\mathcal{L}_I(U,V) = \sum_{u=1}^{n}\sum_{i=1}^{m} (y_{ui} - \mathbf{u}_i^\top \mathbf{v}_u)^2$$

$$\mathcal{R}(U,V) = \|U\|_F^2 + \|U\|_F^2$$

Sử dụng trọng số eta thể hiện mức độ quan trọng giữa các tương tác ẩn và tường minh.

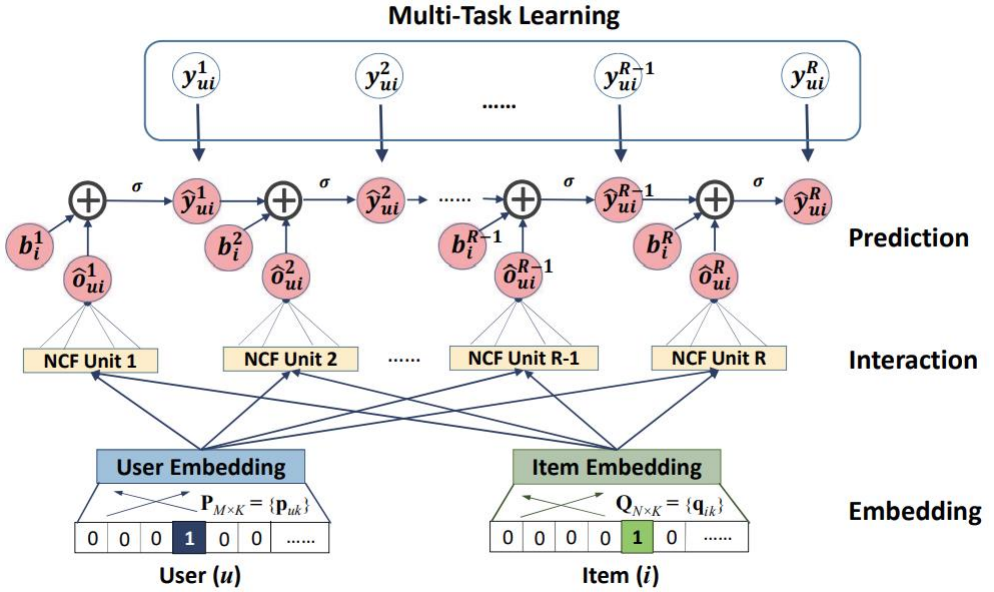
# Neural Multi-Task Recommendation

- Có R loại hành vi khác nhau biểu diễn cho R loại tương tác.
  - ❖ Mỗi loại hành vi được biểu diễn dưới dạng ma trận cỡ MxN, với giá trị mỗi phần tử là giá trị nhị phân.
  - ❖ Các loại hành vi có tính thứ tự từ thấp đến cao, trong đó hành vi cuối cùng được gọi là hành vi mục tiêu.

# Neural Multi-Task Recommendation

- Mã hóa được tính thứ tự của hành vi bằng: Hành vi loại sau phụ thuộc vào hành vi loại trước:

$$\hat{y}_{ui}^{R} = \sigma(\hat{y}_{ui}^{R-1} + f_{\Theta}^{R}(\mathbf{p}_u, \mathbf{q}_i) + b_i^{R}),$$
$$\cdots\cdots$$
$$\hat{y}_{ui}^{2} = \sigma(\hat{y}_{ui}^{1} + f_{\Theta}^{2}(\mathbf{p}_u, \mathbf{q}_i) + b_i^{2}),$$
$$\hat{y}_{ui}^{1} = \sigma(f_{\Theta}^{1}(\mathbf{p}_u, \mathbf{q}_i) + b_i^{1}),$$

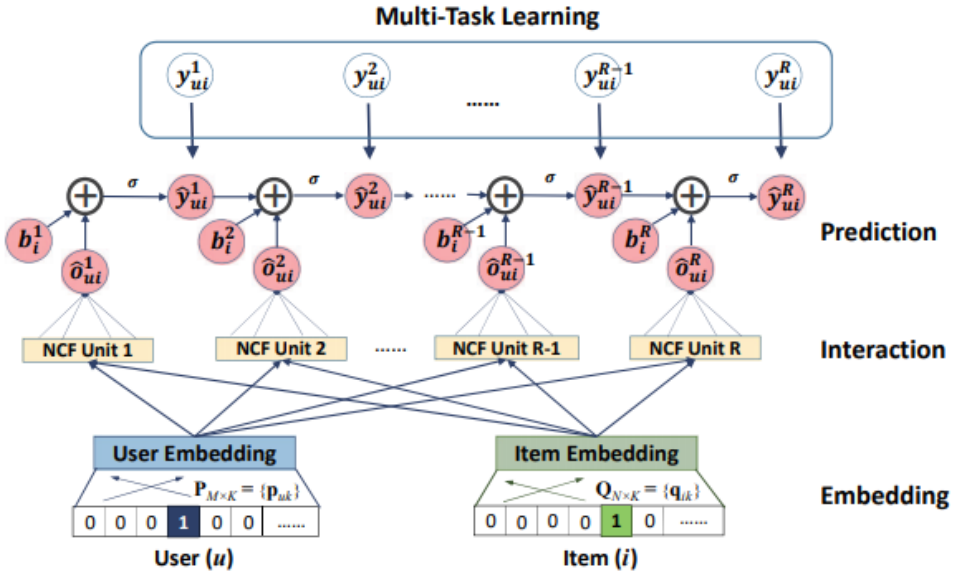


# Neural Multi-Task Recommendation

- Hàm lỗi để học cho tất cả các mô hình con, mỗi mô hình con để tối ưu cho 1 loại hành vi:

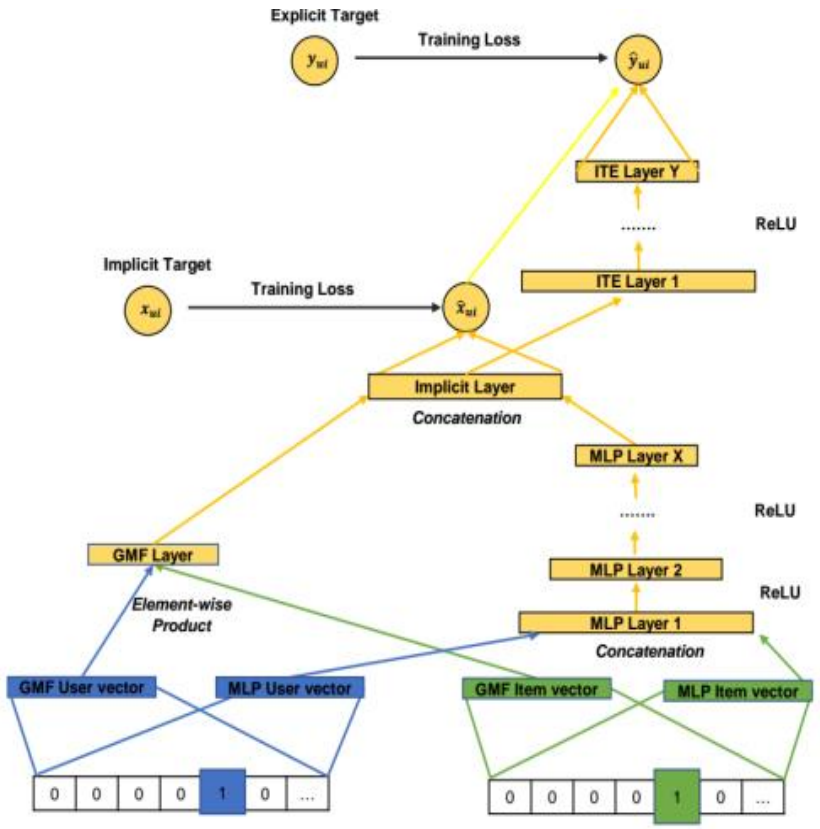
$$L = -\sum_{r=1}^{R} \lambda_r \Big( \sum_{(u,i)\in\mathcal{Y}_r^+} \log \hat{y}_{ui}^r + \sum_{(u,i)\in\mathcal{Y}_r^-} \log(1-\hat{y}_{ui}^r) \Big)$$

  - λr trọng số biểu diễn mức độ ảnh hưởng của từng loại hành vi.



# Implict to Explict model

- Mô hình hóa tính thứ tự của hành vi người dùng.
  - Tầng cuối cùng trong mô hình tương tác tiềm ẩn làm đầu vào cho tầng khác với giá trị đầu ra dự đoán điểm cho tương tác hành vi rõ ràng.
  - ITE-one hot: vector đầu vào là vector one hot mã hóa định danh cho người dùng, sản phẩm.

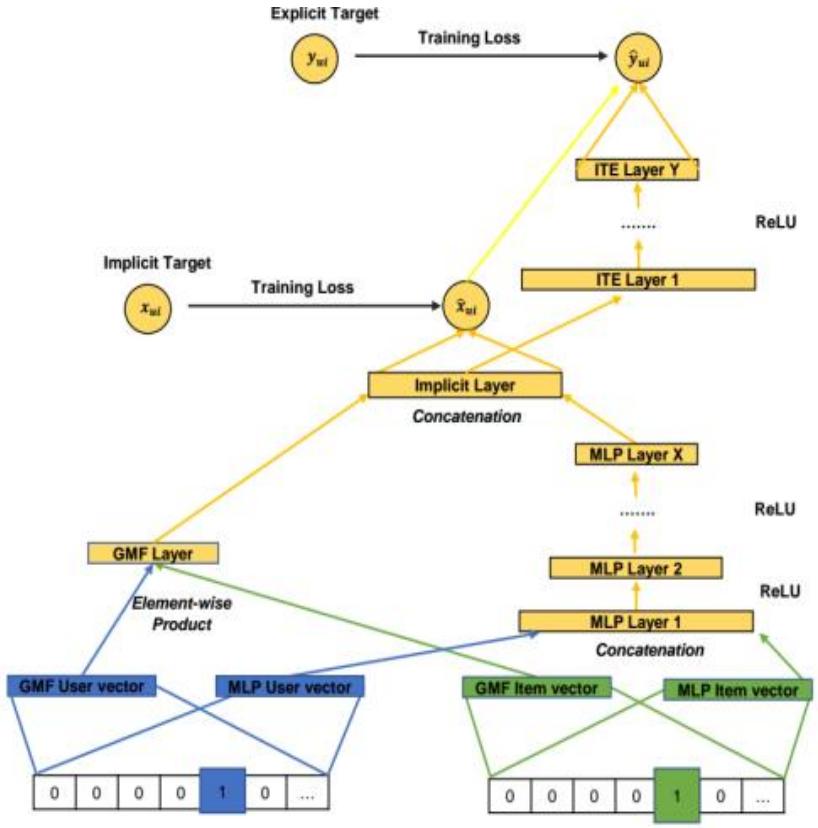


# Implict to Explict model

- Các công thức biểu diễn:

$$\phi^{GMF} = \mathbf{p}_u^G \odot \mathbf{q}_i^G,$$
$$\phi^{MLP} = a_X(\mathbf{W}_X^T(a_{X-1}(...a_2(\mathbf{W}_2^T \begin{bmatrix} \mathbf{p}_u^M \\ \mathbf{q}_i^M \end{bmatrix} + \mathbf{b}_2)...)) + \mathbf{b}_X),$$
$$\phi^I = \begin{bmatrix} \phi^{GMF} \\ \phi^{MLP} \end{bmatrix},$$

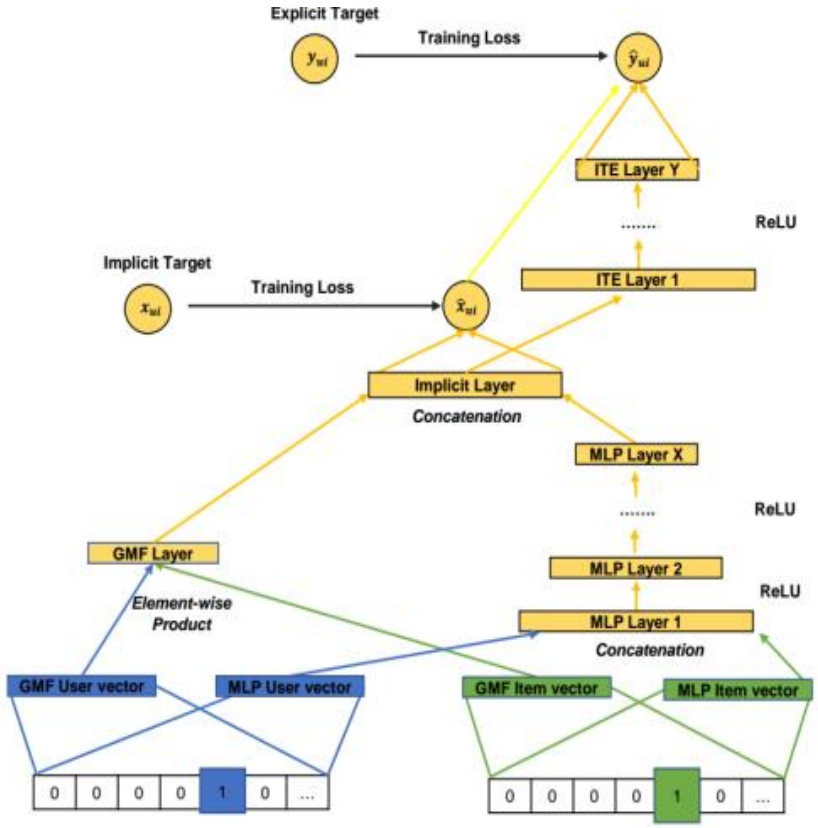
- $\phi^I$ :vector đầu ra cuối cùng của mô hình con trong dự đoán tương tác tiềm ẩn.



# Implict to Explict model

- Các công thức biểu diễn:

$$\hat{x}_{ui} = a_{out}(\mathbf{h}_I^T \phi^I),$$
$$\phi^{ITE} = c_Y(\mathbf{V}_Y^T(c_{Y-1}(...c_2(\mathbf{V}_2^T \phi^{ITE} + \mathbf{d}_2)...)) + \mathbf{d}_Y),$$
$$\hat{y}_{ui} = c_{out}(\mathbf{h}_E^T \phi^{ITE})$$




- $\phi^{ITE}$ :vector đầu ra cuối cùng của mô hình ở tầng cuối cùng trong các tầng đẩy thông qua ITE.
- $\hat{x}_{ui}, \hat{y}_{ui}$ các giá trị dự đoán của hành vi tiềm ẩn và rõ ràng, a với c là hàm sigmoid.

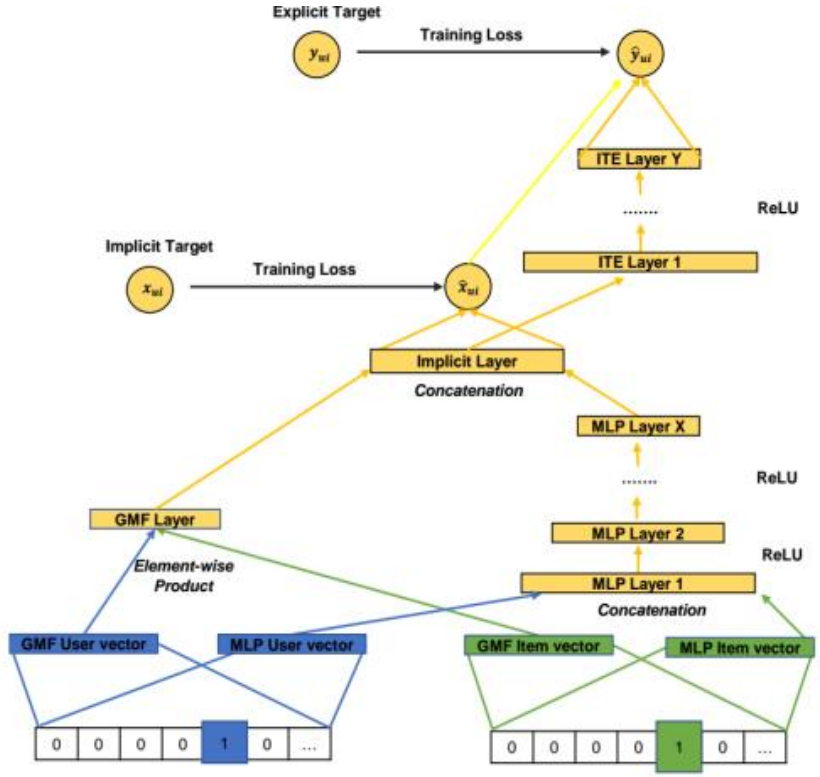
# Implict to Explict model

- Công thức dự đoán mô hình:

$$\phi^I = f^I(\mathbf{u}, \mathbf{i}),$$
$$\hat{x}_{ui} = a_{out}(\mathbf{h}_I^T \phi^I),$$
$$\hat{y}_{ui} = f^{ITE}(\phi^I)$$

❖ Điểm số dự đoán cho tương tác người dùng, sản phẩm:

$$\hat{r}_{ui} = \hat{x}_{ui}\hat{y}_{ui}$$



# Implict to Explict model

- Hàm mục tiêu:

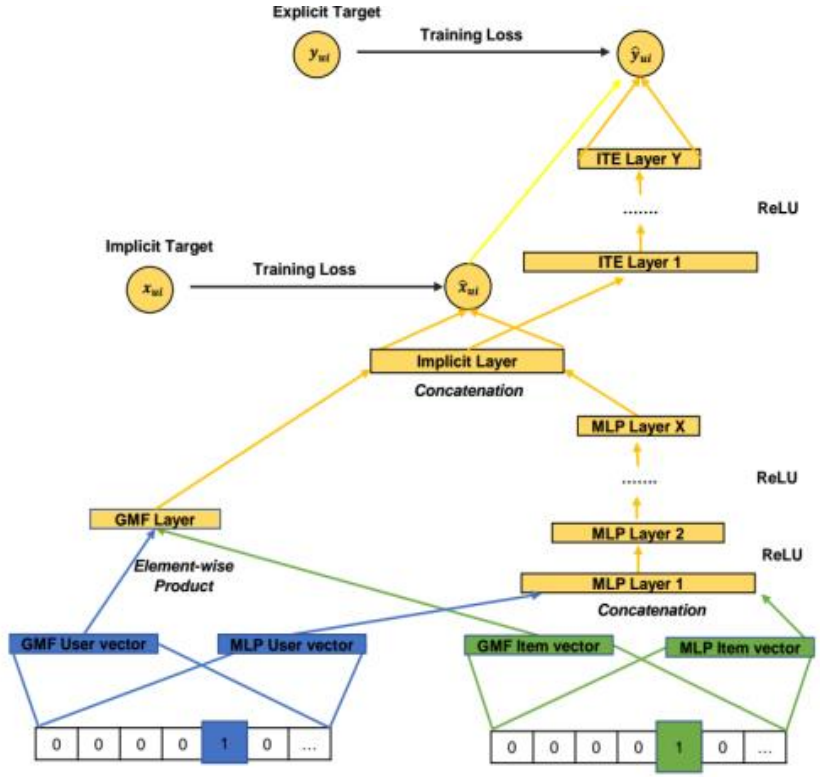
$$\mathcal{L} = \eta\mathcal{L}_I(\hat{x}, x) + \mathcal{L}_E(\hat{y}, y) + \lambda\mathcal{R}(u, i)$$

➢ $\mathcal{L}_I, \mathcal{L}_E$ hàm lỗi của hành vi tường ẩn và rõ ràng.

$$\mathcal{L}_I = \sum_{(u,i)\in\mathcal{X}^+\cup\mathcal{X}^-} x_{ui}\log\hat{x}_{ui} + (1 - x_{ui})\log(1 - \hat{x}_{ui})$$

$$\mathcal{L}_E = \sum_{(u,i)\in\mathcal{Y}^+\cup\mathcal{Y}^-} y_{ui}\log\hat{y}_{ui} + (1 - y_{ui})\log(1 - \hat{y}_{ui})$$

$$\mathcal{R}(u, i) = \sum_u ||\mathbf{p_u}||_2^2 + \sum_i ||\mathbf{q_i}||_2^2$$



# Tài liệu tham khảo

- Slide
  - http://www.recommenderbook.net/teaching-material/slides

- Book


- Dietmar Jannach, Markus Zanker, Alexander Felfernig, Gerhard Friedrich (2010). *Recommender Systems: An Introduction*. Cambridge University Press.
- Francesco Ricci, Lior Rokach, Bracha Shapira, Paul B. Kantor (2015). *Recommender Systems Handbook* (2nd edition). Springer.
- Charu C. Aggarwal (2016). *Recommender Systems: The Textbook*. Springer

# Tài liệu tham khảo


- [He et.al 2017] He, Xiangnan, Lizi Liao, Hanwang Zhang, Liqiang Nie, Xia Hu, and Tat-Seng Chua. "Neural collaborative filtering." In *Proceedings of the 26th international conference on world wide web*, pp. 173-182. 2017.
- [Xue et.al. 2017] Xue, Hong-Jian, Xinyu Dai, Jianbing Zhang, Shujian Huang, and Jiajun Chen. "Deep Matrix Factorization Models for Recommender Systems." In *IJCAI*, vol. 17, pp. 3203-3209. 2017.
- [Tuan et al 2019] Tuan, Anh Phan, Nhat Nguyen Trong, Duong Bui Trong, Linh Ngo Van, and Khoat Than. "From Implicit to Explicit Feedback: A deep neural network for modeling the sequential behavior of online users." In *Asian Conference on Machine Learning*, pp. 1188-1203. 2019.
- [Nathan et al 2010] Nathan N Liu, Evan W Xiang, Min Zhao, and Qiang Yang. Unifying explicit and implicit feedback for collaborative filtering. In *Proceedings of the 19th ACM international conference on Information and knowledge management*, pages 1445{1448. ACM, 2010
- [Chen et al 2019] Chen Gao, Xiangnan He, Dahua Gan, Xiangning Chen, Fuli Feng, Yong Li, Tat-Seng Chua, and Depeng Jin. Neural multi-task recommendation from multi-behavior data. In *2019 IEEE 35th International Conference on Data Engineering (ICDE)*, pages 1554-1557. IEEE, 2019.
- [He et al 2020] He, X., Deng, K., Wang, X., Li, Y., Zhang, Y., & Wang, M. (2020, July). Lightgcn: Simplifying and powering graph convolution network for recommendation. In *Proceedings of the 43rd International ACM SIGIR conference on research and development in Information Retrieval* (pp. 639-648).

HUST

hust.edu.vn fb.com/dhbkhn

# THANK YOU !