Script thuyết trình CineMatch

Oct 23, 2026 · @DATA OPENDB

Tổng quan

Bài nói dài khoảng 14 phút cho 17 slide, chia cho 3 người, để dư 1 phút trong giới hạn 15 phút trước phần hỏi đáp.

Phân vai trên là đề xuất theo mạch nội dung; nhóm có thể đổi người mà không cần sửa lời thoại.

Cách đọc script:

- Chữ trong ngoặc vuông, ví dụ *[chuyển slide]*, là hành động, không đọc ra.
- Lời thoại là gợi ý để nói theo ý. Không đọc nguyên văn trên slide.
- Mỗi người tập riêng phần mình và bấm giờ. Nếu quá thời lượng, rút bớt ví dụ chứ không bỏ câu chuyển giao.
- Khi nói về biểu đồ, chỉ tay vào đúng điểm đang nhắc tới (cột 4★, điểm 10% → 60%).

Phần 1 — (slide 1–5, 4 phút)

Slide 1 · Bìa (30 giây)

Em chào cô và các bạn. Nhóm em gồm ba thành viên: em là Hoàng Đức Anh, cùng hai bạn Phạm Đức Anh và Trần Quý Đôn, dưới sự hướng dẫn của cô Nguyễn Thị Kim Anh.

Đề tài của nhóm là CineMatch, một hệ gợi ý phim cá nhân hoá có giải thích. Hôm nay nhóm trình bày bài toán, bộ dữ liệu và hướng xử lý dự kiến. *[chuyển slide]*

Slide 2 · Nội dung trình bày (20 giây)

Bài trình bày gồm năm phần. Đầu tiên là bối cảnh và phát biểu bài toán. Tiếp theo là bộ dữ liệu MovieLens và hướng xử lý. Cuối cùng là cách đánh giá và kế hoạch thực hiện. *[chuyển slide]*

Slide 3 · Bối cảnh và động lực (1 phút)

Các nền tảng như Netflix hay YouTube có kho nội dung rất lớn. Người dùng không thể tự duyệt hết để tìm phim mình thích.

Thêm vào đó, mỗi người một gu. Một danh sách “phim hot” chung cho tất cả mọi người sẽ không phù hợp.

Vấn đề thứ ba là người dùng mới. Hệ thống cần gợi ý được ngay khi họ mới chọn vài phim yêu thích.

[chỉ vào khung kịch bản] Kịch bản nhóm hướng tới: người dùng mở ứng dụng và nhận 10 phim nên xem tiếp, kèm lý do, ví dụ "vì bạn thích Interstellar và Inception". Phần lý do này là điểm riêng của CineMatch. *[chuyển slide]*

Slide 4 · Phát biểu bài toán (1 phút)

Bài toán có hai mục tiêu.

Mục tiêu chính là top-N recommendation. Từ lịch sử chấm điểm của một người, hệ thống xếp hạng toàn bộ phim họ chưa xem và trả về 10 phim họ có khả năng thích nhất.

Mục tiêu phụ là dự đoán điểm, trên thang 0.5 đến 5 sao, để hiển thị "điểm dự đoán" cho từng phim.

[chỉ vào khung dưới] Hai mục tiêu này không trùng nhau. Một mô hình dự đoán điểm rất chính xác chưa chắc đã xếp hạng tốt. Vì vậy nhóm sẽ đo hai mục tiêu bằng hai bộ chỉ số riêng. *[chuyển slide]*

Slide 5 · Đầu vào và đầu ra (1 phút)

Về đầu vào, hệ thống nhận lịch sử chấm điểm của người dùng, thông tin phim gồm thể loại, tag, năm, và các tuỳ chọn như số phim hay lọc thể loại.

Về đầu ra, hệ thống trả về top-N phim đã xếp hạng, điểm số của từng phim, và lý do gợi ý: phim đó được đề xuất nhờ những phim nào bạn đã xem.

Một điểm quan trọng: người dùng được biểu diễn bằng lịch sử, không phải bằng ID. Nên người mới chỉ cần chọn vài phim là có gợi ý ngay, không phải huấn luyện lại mô hình.

Chuyển giao: Để biết hệ thống học từ dữ liệu nào, em xin mời bạn Phạm Đức Anh trình bày về bộ dữ liệu MovieLens. *[chuyển slide]*

Phần 2 — (slide 6–9, 4 phút)

Slide 6 · Bộ dữ liệu MovieLens (1 phút)

Cảm ơn Đức Anh. Nhóm em dùng bộ MovieLens ml-latest-small của nhóm GroupLens, bộ dữ liệu chuẩn trong nghiên cứu hệ gợi ý.

[chỉ vào bốn con số] Bộ này có 610 người dùng, mỗi người chấm ít nhất 20 phim. Có 9.742 phim thuộc 20 thể loại, và hơn 100 nghìn lượt chấm điểm từ năm 1996 đến 2018.

Dữ liệu gồm bốn file. Quan trọng nhất là ratings.csv, chứa ai chấm phim nào, mấy sao, vào lúc nào. File movies.csv cho tên, năm và thể loại phim. File tags.csv chứa các tag tự do do người dùng gắn. File links.csv liên kết sang IMDb và TMDB. *[chuyển slide]*

Slide 7 · Phân phối điểm (1 phút)

[chỉ vào cột 4★] Biểu đồ này cho thấy tỷ lệ lượt chấm theo từng mức điểm. Mức 4 sao phổ biến nhất, chiếm 26,6%. Điểm trung bình là 3,5 sao, tức là lệch về phía cao.

Các mức điểm nguyên như 3, 4, 5 sao cũng phổ biến hơn các mức nửa sao.

Điều nhóm rút ra là "bias": có người dễ tính, hay chấm cao; có người khó tính. Có phim được đánh giá cao hơn hẳn mặt bằng chung. Mô hình cần tách riêng hai yếu tố này trước khi học sở thích thật. *[chuyển slide]*

Slide 8 · Thưa và long-tail (1 phút)

Dữ liệu rất thưa. Nếu xếp thành ma trận người dùng nhân phim, 98,3% số ô là trống.

[chỉ vào điểm đỏ trên đường cong] Đường cong này xếp phim từ phổ biến nhất tới ít phổ biến nhất. Chỉ 10% phim đầu tiên đã chiếm 60% tổng số lượt chấm. Đây là hiện tượng long-tail.

Ở phía đuôi, 35% số phim chỉ có đúng một lượt chấm. Tag cũng rất thưa, chỉ 16% phim có tag. *[chuyển slide]*

Slide 9 · Từ đặc điểm dữ liệu tới thiết kế (1 phút)

Từ bốn đặc điểm trên, nhóm đưa ra bốn quyết định thiết kế.

- Ma trận rất thưa, nên cần regularization và phạt những độ tương đồng ít bằng chứng, gọi là shrinkage.
- Điểm lệch theo người và theo phim, nên mô hình hoá phần bias $\mu + b_u + b_i$ trước.
- Long-tail mạnh, nên cách đơn giản nhất là gợi ý phim phổ biến đã rất khó vượt. Nhóm dùng nó làm mốc bắt buộc, và đo thêm độ đa dạng.
- Phim mới, ít lượt chấm, cần thêm thông tin nội dung như thể loại, tag và năm.

Chuyển giao: Các quyết định này được hiện thực thế nào, em xin mời bạn Trần Quý Đôn trình bày hướng xử lý. *[chuyển slide]*

Phần 3 — (slide 10–14, 5 phút)

Slide 10 · Hướng xử lý tổng quan (45 giây)

Cảm ơn Đức Anh. Nhóm em đi theo bốn bước, từ đơn giản tới phức tạp. *[chỉ lần lượt bốn khối]* Bước một là baseline để làm mốc. Bước hai là lọc cộng tác. Bước ba là gợi ý dựa trên nội dung. Bước bốn kết hợp hai hướng thành mô hình lai.

Hai nguyên tắc xuyên suốt: mọi mô hình chạy trên cùng cách chia dữ liệu và cùng bộ chỉ số để so sánh công bằng. Và mỗi gợi ý đều có giải thích: điểm của nó được tách thành đóng góp của từng phim đã xem hoặc từng đặc trưng nội dung. *[chuyển slide]*

Slide 11 · Bước 1: Baseline (1 phút)

Nhóm dùng bốn baseline.

- Random xếp ngẫu nhiên, là mức sàn. Mọi mô hình phải vượt xa nó.
- Popularity gợi ý phim nhiều người chấm nhất. Nghiên cứu của Cremonesi và cộng sự cho thấy trên dữ liệu long-tail, cách này rất mạnh dù không cá nhân hoá.
- Top-rated xếp theo điểm trung bình có làm mịn Bayes. Nhờ vậy, một phim chỉ có một lượt 5 sao sẽ không nhảy lên đầu.
- Bias dự đoán điểm bằng $\mu + b_u + b_i$: trung bình chung, cộng độ dễ tính của người, cộng độ hay của phim. Đây là baseline chuẩn cho dự đoán điểm. *[chuyển slide]*

Slide 12 · Bước 2: Lọc cộng tác (1 phút 15 giây)

Bước hai là ba kỹ thuật lọc cộng tác.

[chỉ cột Item-kNN] Item-kNN tìm những phim giống với phim bạn đã thích. Độ giống là cosine tính trên phần dư sau khi đã bỏ bias, nhân với hệ số shrinkage để phạt các cặp phim ít người xem chung. Ưu điểm lớn nhất là dễ giải thích.

[chỉ cột MF-ALS] MF-ALS biểu diễn mỗi người và mỗi phim bằng một vector ẩn. Điểm dự đoán là bias cộng tích vô hướng của hai vector, tối ưu bằng bình phương tối thiểu luân phiên.

[chỉ cột EASE] EASE làm việc trên phản hồi ngầm: đã xem là 1, chưa xem là 0. Nó học một ma trận phim–phim có nghiệm đóng, không cần vòng lặp. Vì học trực tiếp "phim nào người dùng sẽ chọn xem", nó khớp với mục tiêu top-N hơn. *[chuyển slide]*

Slide 13 · Bước 3–4: Content-based và Hybrid (1 phút)

[chỉ khối bên trái] Gợi ý dựa trên nội dung biểu diễn mỗi phim bằng vector TF-IDF. Thể loại có trọng số cao nhất, rồi đến tag, rồi đến thập niên. Hồ sơ người dùng được kéo về phía phim họ chấm cao hơn trung bình của mình.

Ưu điểm là gợi ý được cả phim mới, ít lượt chấm. Nhược điểm là nó chỉ biết hai phim "giống nhau", không biết phim nào "hay".

[chỉ khối bên phải] Vì vậy nhóm kết hợp thành mô hình lai. Điểm của lọc cộng tác và của content được chuẩn hoá rồi cộng có trọng số w. Trọng số này được chọn trên tập validation. *[chuyển slide]*

Slide 14 · Kế hoạch đánh giá (1 phút)

[chỉ thanh train/test] Nhóm chia dữ liệu theo thời gian, riêng cho từng người. Với mỗi người, 80% lượt chấm cũ nhất dùng để huấn luyện, 20% mới nhất dùng để kiểm tra. Như vậy mô hình không dùng tương lai để đoán quá khứ, đúng với cách hệ thống được dùng thật.

Phim được chấm từ 4 sao trở lên ở tập kiểm tra được coi là phù hợp.

Chỉ số chia ba nhóm. RMSE và MAE đo dự đoán điểm. NDCG@10, Precision, Recall và HitRate đo xếp hạng; trong đó NDCG@10 là chỉ số chính vì nó thưởng cho việc đưa phim phù hợp lên đầu danh sách. Coverage và Novelty đo độ đa dạng và mới lạ.

Chuyển giao: Em xin mời bạn Hoàng Đức Anh trình bày kế hoạch thực hiện. *[chuyển slide]*

Phần 4 — (slide 15–17, 1 phút)

Slide 15 · Kế hoạch thực hiện (40 giây)

Cảm ơn Đôn. Nhóm chia công việc thành năm giai đoạn. *[chỉ lần lượt]* Đầu tiên là đề xuất đề tài và khảo sát. Sau đó là tiền xử lý dữ liệu và cài đặt baseline, rồi đến lọc cộng tác và content-based. Tiếp theo là mô hình lai và đánh giá. Cuối cùng là demo và báo cáo.

Sản phẩm cuối kỳ gồm mã nguồn, file hướng dẫn chạy, báo cáo PDF, bài trình bày và hệ thống demo. *[chuyển slide]*

Khi slide đã điền tuần và người phụ trách, nói thêm mỗi giai đoạn một cụm, ví dụ "tuần 5–6, Đôn phụ trách".

Slide 16 · Tài liệu tham khảo (10 giây)

Đây là các tài liệu nhóm tham khảo, đánh số khớp với trích dẫn trên các slide trước. *[chuyển slide ngay, không đọc từng dòng]*

Slide 17 · Cảm ơn (10 giây)

Phần trình bày của nhóm em đến đây là kết thúc. Em cảm ơn cô và các bạn đã lắng nghe. Nhóm em rất mong nhận được câu hỏi và góp ý để hoàn thiện đề tài.

Chuẩn bị hỏi đáp

Người trình bày phần liên quan trả lời trước; người khác chỉ bổ sung khi cần. Trả lời ngắn, đúng câu hỏi, rồi dừng.

Câu hỏi có thể gặp	Người trả lời	Gợi ý trả lời
“Giải thích” của nhóm khác LIME hay SHAP thế nào?	Trần Quý Đôn	LIME và SHAP xấp xỉ lại mô hình sau khi đã có kết quả. Các mô hình của nhóm tuyến tính theo lịch sử người dùng khi tham số đã cố định. Vì vậy điểm tách được chính xác thành tổng đóng góp của từng phim đã xem, không phải xấp xỉ.
Sao không chia train/test ngẫu nhiên?	Trần Quý Đôn	Chia ngẫu nhiên cho mô hình thấy tương lai khi đoán quá khứ, nên kết quả đẹp hơn thực tế. Chia theo thời gian khó hơn nhưng đúng với việc gợi ý “phim xem tiếp theo”.
Vì sao NDCG@10 là chỉ số chính?	Trần Quý Đôn	Người dùng chủ yếu nhìn vài phim đầu. NDCG thưởng nhiều hơn khi phim phù hợp nằm ở vị trí cao. Precision và Recall chỉ đếm có hay không, bỏ qua thứ tự.
Vì sao chọn EASE?	Trần Quý Đôn	EASE học trên phản hồi ngầm, khớp với mục tiêu top-N. Nó có nghiệm đóng nên đơn giản, và là baseline rất mạnh trong các so sánh gần đây [4].
Popularity mạnh như vậy thì cá nhân hoá có đáng không?	Phạm Đức Anh	Chính vì vậy Popularity là mốc bắt buộc. Nhóm đặt mục tiêu mô hình tốt nhất vượt Popularity ít nhất 20% về NDCG@10. Ngoài ra Popularity gợi ý cùng một danh sách cho mọi người, nên Coverage rất thấp.
Phim mới hoặc người dùng mới thì xử lý ra sao?	Hoàng Đức Anh	Người dùng mới: hệ thống biểu diễn người dùng bằng lịch sử, nên chọn vài phim là có gợi ý, không cần huấn luyện lại. Phim mới chưa có lượt chấm: lọc cộng tác không xử lý được, nên cần content-based và hybrid.

Câu hỏi có thể gặp	Người trả lời	Gợi ý trả lời
Sao dùng bản small mà không dùng ml-25m?	Phạm Đức Anh	Bản small chạy nhanh, đủ để so sánh nhiều mô hình và tune tham số trong thời gian môn học. Chạy trên ml-25m để kết quả ổn định hơn là hướng mở rộng.
Ngưỡng “phù hợp” 4 sao lấy từ đâu?	Phạm Đức Anh	Đây là ngưỡng thường dùng với MovieLens. Vì điểm lệch về phía cao, mức 3 sao chỉ là “bình thường”, còn từ 4 sao trở lên mới thể hiện là thích.
Có dùng deep learning không?	Trần Quý Đôn	Giai đoạn này chưa. Nhóm ưu tiên các mô hình giải thích được chính xác. Mô hình tuần tự như SASRec hoặc LightGCN là hướng phát triển sau.